

Laboratorio 10 - Análisis de Regresión

Daniel Saavedra y Mauricio Toro

Departamento de Estadística
Pontificia Universidad Católica de Chile

Jueves 23 de Abril, 2026



Contenidos

Introducción

Análisis de Regresión

Actividades

Motivación

- ▶ Suponga que estamos interesados en estudiar la relación entre las horas de estudio a una evaluación y el rendimiento de un grupo de estudiantes.

Motivación

- ▶ Suponga que estamos interesados en estudiar la relación entre las horas de estudio a una evaluación y el rendimiento de un grupo de estudiantes.
- ▶ Existen teorías y evidencia empírica que sugiere una relación entre las horas de estudio y el rendimiento académico.


Motivación

- ▶ Suponga que estamos interesados en estudiar la relación entre las horas de estudio a una evaluación y el rendimiento de un grupo de estudiantes.
- ▶ Existen teorías y evidencia empírica que sugiere una relación entre las horas de estudio y el rendimiento académico.
- ▶ En general, se ha encontrado que dedicar más tiempo al estudio está asociado con un mejor rendimiento académico.



Motivación

- ▶ Suponga que estamos interesados en estudiar la relación entre las horas de estudio a una evaluación y el rendimiento de un grupo de estudiantes.
- ▶ Existen teorías y evidencia empírica que sugiere una relación entre las horas de estudio y el rendimiento académico.
- ▶ En general, se ha encontrado que dedicar más tiempo al estudio está asociado con un mejor rendimiento académico.
- ▶ Sin embargo, al tomar una muestra y evaluar ambas variables nos encontramos con la siguiente situación.

Ejemplo



Ejemplo



Explicación

La explicación se debe a la presencia de factores no observados que influyen directamente en el fenómeno de estudio.

Estudiante	Factores Observables		Factores No Observables			
	Estudio (Horas)	Calificación (Nota)	Horas de sueño	¿Estuvo concentrado?	Método estudio	Etc...
1	1,0	3,9	Normal	Si	A	...
2	1,5	3,5	Menor	No	B	...
3	2,0	4,5	Normal	Si	A	...
4	2,5	5,4	Normal	Si	A	...
5	3,0	5,4	Menor	Si	B	...
6	3,5	7,0	Mayor	Si	A	...
7	4,0	6,1	Menor	No	B	...

¿Podemos llegar a controlar o al menos medir todos los factores que inciden en nuestro estudio?.

Modelo

Si representamos lo anterior a través de una ecuación:

$$\underbrace{\text{Calificación}}_{\text{Interés (Y)}} = \underbrace{\text{Estudio}}_{\text{Observado (X)}} + \underbrace{\text{Sueño} + \text{Concentración} + \dots}_{\text{No Observado } (\epsilon)},$$

donde ϵ representa todos aquellos factores que no fueron medidos en el estudio pero que sí explican la variable de interés. De esta manera, la magnitud de ϵ cuantificará en alguna forma qué tanto contribuyen estos factores no observados en la muestra recolectada.

Variabilidad

- ▶ En estadística la variabilidad se debe a la incerteza (imperfección en el conocimiento sobre el estado o los procesos de la naturaleza) ganada tras no medir todos aquellos factores que afectan directamente al fenómeno de estudio.


Variabilidad

- ▶ En estadística la variabilidad se debe a la incerteza (imperfección en el conocimiento sobre el estado o los procesos de la naturaleza) ganada tras no medir todos aquellos factores que afectan directamente al fenómeno de estudio.
- ▶ Con ello, no buscamos tener control sobre todas estas variables, sino más bien considerarlas como una componente activa en el análisis de los resultados.

Variabilidad

- ▶ En estadística la variabilidad se debe a la incerteza (imperfeción en el conocimiento sobre el estado o los procesos de la naturaleza) ganada tras no medir todos aquellos factores que afectan directamente al fenómeno de estudio.
- ▶ Con ello, no buscamos tener control sobre todas estas variables, sino más bien considerarlas como una componente activa en el análisis de los resultados.
- ▶ Cada vez que controlamos alguna variable de perturbe el fenómeno de estudio se puede esperar una disminución de la variabilidad de la variable de interés, mejorando el conocimiento que se hubiera obtenido si no se hubiera observado.

Variabilidad



Modelos deterministas y aleatorios

- ▶ **Modelo determinista:** es aquel en el que el resultado está completamente determinado por las condiciones iniciales y las reglas o leyes que gobiernan el sistema en cuestión. Si se conocen todas las variables y parámetros relevantes, se puede predecir con certeza cuál será el resultado.

Modelos deterministas y aleatorios

- ▶ **Modelo determinista:** es aquel en el que el resultado está completamente determinado por las condiciones iniciales y las reglas o leyes que gobiernan el sistema en cuestión. Si se conocen todas las variables y parámetros relevantes, se puede predecir con certeza cuál será el resultado.
- ▶ **Modelo aleatorio:** es aquel en el que el resultado no se puede predecir con certeza debido a la presencia de factores aleatorios o de azar. No se puede afirmar con seguridad cuál será el resultado específico en una sola realización del experimento. Los experimentos aleatorios están sujetos a la incertidumbre y a la variabilidad inherente.

Análisis de regresión

El análisis de regresión es una técnica estadística que permite estudiar la relación entre una variable dependiente (respuesta) y una o más variables independientes (predictoras).

Análisis de regresión

El análisis de regresión es una técnica estadística que permite estudiar la relación entre una variable dependiente (respuesta) y una o más variables independientes (predictoras).

Objetivos principales:

- ▶ Comprender cómo varía la variable de interés cuando cambian las variables que la podrían influir.
- ▶ Evaluar la fuerza y dirección de estas relaciones.
- ▶ Realizar predicciones basadas en datos observados.

Análisis de regresión

El análisis de regresión es una técnica estadística que permite estudiar la relación entre una variable dependiente (respuesta) y una o más variables independientes (predictoras).

Objetivos principales:

- ▶ Comprender cómo varía la variable de interés cuando cambian las variables que la podrían influir.
- ▶ Evaluar la fuerza y dirección de estas relaciones.
- ▶ Realizar predicciones basadas en datos observados.

En esta clase aprenderemos a aplicar la regresión lineal simple en **Excel**, interpretando los coeficientes del modelo, los gráficos y los indicadores de ajuste.

Base de datos: school


La base de datos lab10.xlsx, hoja "school" contiene información de 200 estudiantes de secundaria en Estados Unidos.

- ▶ **female**: Sexo del estudiante.
- ▶ **ses**: Nivel socioeconómico del estudiante.
- ▶ **read**: Puntaje obtenido en la prueba de lectura.
- ▶ **write**: Puntaje obtenido en la prueba de escritura.
- ▶ **math**: Puntaje obtenido en la prueba de matemáticas.
- ▶ **science**: Puntaje obtenido en la prueba de ciencias.
- ▶ **socst**: Puntaje obtenido en la prueba de estudios sociales.

A continuación, realizaremos un análisis de regresión.

Gráfico de dispersión

El gráfico de dispersión permite ver de manera inmediata si existe una relación lineal entre la variable dependiente y la independiente.



Si los puntos se agrupan alrededor de una línea recta, sugiere una relación lineal, que es el supuesto básico de la regresión lineal.

Coeficiente de correlación

El coeficiente de correlación mide la fuerza y dirección de la relación lineal entre dos variables cuantitativas. Se define como:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}},$$

donde $-1 < r < 1$.

- ▶ $r > 0$: relación positiva (cuando una variable aumenta, la otra tiende a aumentar).
- ▶ $r < 0$: relación negativa (cuando una variable aumenta, la otra tiende a disminuir).
- ▶ $|r|$ cercano a 1 indica una fuerte relación lineal.
- ▶ $|r|$ cercano a 0 indica una relación débil o nula.

En Excel lo podemos calcular mediante `=COEF.DE.CORREL( ; )`.

Modelo de regresión lineal simple

Consideremos el siguiente modelo de regresión lineal simple:

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i,$$

donde

- ▶ y_i : Puntaje obtenido en matemáticas del i -ésimo individuo.
- ▶ x_i : Puntaje obtenido en lectura del i -ésimo individuo.
- ▶ β_0 : Intercepto (representa el puntaje en matemáticas cuando el puntaje en lectura es cero).
- ▶ β_1 : Pendiente (indica el cambio en el puntaje en matemáticas por cada unidad de cambio en el puntaje de lectura).
- ▶ ϵ_i : Error (refleja la variabilidad no explicada por la relación lineal entre lectura y matemáticas).

Estimación

Para estimar los coeficientes β_0 y β_1 , podemos utilizar el **método de los mínimos cuadrados ordinarios (MCO)**. Este método busca minimizar la suma de los residuos al cuadrado, es decir, la diferencia entre los valores observados y los valores predichos por el modelo:


$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{(\beta_0, \beta_1)} \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2$$

Los valores de β_0 y β_1 que minimizan esta expresión son:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2},$$
$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x},$$


Estimación en Excel

Primero se debe crear un gráfico de dispersión con las variables de interés. Luego, se debe agregar una línea de tendencia al gráfico seleccionando la opción Línea de tendencia -> Lineal.



Estimación en Excel

Desde este panel Formato de línea de tendencia se pueden realizar diversas configuraciones, como mostrar la ecuación de la y visualizar el valor del coeficiente de determinación R^2 .



Es posible personalizar el estilo de la línea de tendencia como Formato.

Modelo ajustado

El modelo de regresión lineal estimado es:

$$\hat{y}_i = 0.6051x_i + 21.038,$$

Interpretación:

- ▶ Dado que $\hat{\beta}_1 > 0$, se observa una relación positiva entre las variables: a medida que aumenta el puntaje en lectura, también tiende a aumentar el puntaje en matemáticas.
- ▶ En particular, por cada punto adicional en lectura, el modelo predice un aumento promedio de 0.6051 puntos en matemáticas.
- ▶ En cuanto al intercepto, este indica que, si el puntaje en lectura fuese 0, el puntaje en matemáticas esperado es de 21.038.

Cuando la variable explicativa no puede asumir el valor 0, por razones prácticas o por alguna restricción, el intercepto no se interpreta.

Coeficiente de determinación

El coeficiente de determinación mide la proporción de la variabilidad total de la variable dependiente que es explicada por el modelo de regresión. Este se define como:

$$R^2 = \left(\frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \right)^2,$$

donde $0 < R^2 < 1$.

- ▶ Un valor cercano a 1 indica que el modelo explica gran parte de la variabilidad observada en los datos. Un valor cercano a 0 sugiere que el modelo tiene poca capacidad explicativa.
- ▶ En una regresión lineal simple, el coeficiente de determinación R^2 es igual al cuadrado del coeficiente de correlación r .
- ▶ Mientras r indica la fuerza y dirección de la relación lineal, R^2 muestra qué proporción de la variación en una variable puede explicarse por la otra.

Coeficiente de determinación

Interpretación

En el ejemplo anterior:

- ▶ El valor de R^2 indica el porcentaje de variabilidad en los puntajes de matemáticas que se explica por el modelo de regresión lineal con puntajes de lectura.
- ▶ En este caso, $R^2 = 0.4386$ significa que aproximadamente el 43,86% de la variabilidad en los puntajes de matemáticas se puede explicar por una función lineal del puntaje en lectura.
- ▶ Por tanto, el 56,14% restante de la variabilidad en los puntajes de matemáticas no se explica por este modelo, lo que sugiere que podrían existir otros factores que influyen en los resultados de matemáticas y que no están siendo considerados.

Predicción

El modelo de regresión ajustado permite estimar el valor de la variable dependiente a partir de un valor dado x_0 de la variable explicativa. La predicción se calcula como:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$





Este valor predicho corresponde al **valor esperado** de la variable dependiente para un individuo con valor x_0 en la variable explicativa, según la relación lineal estimada a partir de los datos.

Ejemplo: Si un estudiante obtuvo un puntaje de 60 en lectura, su puntaje esperado en matemáticas es:

$$\hat{y} = 21.038 + 0.6051 \cdot 60 = 57.344.$$

Otro tipo de modelos

Excel nos permite ajustar no solo una recta, sino también curvas más complejas, como modelos cuadráticos, exponenciales o de potencia.



Modelo de regresión simple v/s modelos más complejos

Beneficios de usar modelos no lineales

- ▶ Permiten capturar patrones más complejos que una recta.
- ▶ Mejoran su capacidad de ajuste (aumentan el R^2).

Sin embargo, aunque pueda parecer buena idea usar una curva más compleja solo porque el R^2 es más alto, eso no siempre significa que el modelo es mejor.

Desventajas de usar modelos más complejos:

- ▶ Una ecuación más difícil de interpretar.
- ▶ El modelo se ajusta muy bien a los datos actuales, pero podría fallar al predecir nuevos casos.

Parsimonia

En estadística, no se trata únicamente de encontrar el modelo que mejor se ajusta a los datos en términos numéricos, sino también de mantener la interpretación lo más sencilla posible. Esto se conoce como el **principio de parsimonia**:

El modelo más simple que explique adecuadamente los datos es preferible.

Por lo tanto, solo si los datos muestran claramente una forma no lineal vale la pena considerar modelos más complejos.

Actividad I

Utilizando la base de datos "school", ajuste un modelo de regresión lineal simple para predecir el puntaje en ciencias sociales a partir del puntaje en lectura.

- ▶ ¿Cuál es la ecuación de la recta ajustada? ¿Qué representa la pendiente y el intercepto en este contexto?
- ▶ Reporte el valor de R^2 e interprete su significado.
- ▶ Utilice el modelo para predecir el puntaje en ciencias sociales de un estudiante con los siguientes puntajes de lectura: 55 y 70. ¿Qué tan confiables considera que son estas predicciones?
- ▶ Compare el ajuste del modelo lineal con el de un modelo logarítmico. ¿El modelo logarítmico mejora el ajuste en comparación con la recta? Justifique su respuesta.

Actividad II

Considere el archivo `Lab10_Anscombe.xlsx`, el cual fue publicado por Francis John Anscombe ([enlace ↗](#)). Este archivo está compuesta por **4 conjuntos de datos** que, a pesar de compartir estadísticas similares, muestran comportamientos muy distintos al ser representados gráficamente.

- ▶ Calcule la media y la varianza de las variables X e Y en cada conjunto de datos. Comente sus resultados.
- ▶ Calcule el coeficiente de correlación entre X e Y en cada conjunto. Comente sus resultados.
- ▶ Para cada conjunto, realice un diagrama de dispersión, ajuste un modelo de regresión lineal simple, y muestre la recta estimada junto con el coeficiente de determinación (R^2).
- ▶ ¿Por qué es importante complementar los cálculos numéricos con representaciones gráficas en un análisis de regresión?