

Laboratorio 12 - Limpieza bases de datos

Daniel Saavedra y Mauricio Toro

Departamento de Estadística
Pontificia Universidad Católica de Chile

Martes 5 de mayo, 2026



Contenidos

Introducción

Funciones de limpieza de texto

Extraer o reemplazar texto

Funciones lógicas y condicionales

Manejo de fechas

Tarea

Introducción

- ▶ Las bases de datos con las que hemos practicado —sin duplicados ni datos faltantes— son excepciones; en la práctica los datos casi nunca llegan tan *pulidos*.
- ▶ Algunos errores típicos en las bases de datos son
 - ▶ nombres de categorías inconsistentes
 - ▶ fechas imposibles o inexistentes
 - ▶ números fuera de rango (*¡no es lo mismo que datos atípicos!*)

Por lo tanto, realizar una revisión de la base de datos antes del análisis es fundamental, ya los errores pueden alterar los estadísticos y modelos utilizados, lo que podría conducir a conclusiones erróneas.

¿Qué debemos hacer?

- ▶ **Detección sistemática:** el primer paso es perfilar la base (tablas de frecuencia, resúmenes estadísticos, gráficos) para localizar rápidamente anomalías y valores faltantes.
- ▶ **Estandarizar y validar:** unificar nombres de categorías, normalizar formatos (fechas, decimales) y chequear rangos admisibles reduce errores antes de cualquier análisis.
- ▶ **Estrategias ante datos faltantes (missing data):** existen diferentes estrategias para el análisis de datos faltantes: descartar casos, reemplazar el dato faltante (imputación), entre otras. La acción a realizar depende del patrón de missing y siempre es necesario declarar criterio utilizado y sus consecuencias.
- ▶ **Reproducibilidad:** hoy en día se recomienda registrar cada transformación para garantizar que el proceso pueda replicarse, auditarse y mejorarse en futuros proyectos.

Bases de datos: compras

La base de datos `compras.xlsx` tiene el registro de las compras realizadas por diferentes clientes en empresas de un gran consorcio comercial. Las variables son:

- ▶ `Nombre_Apellido`: nombre y apellido del vendedor con el que se hizo la compra.
- ▶ `Local`: tienda donde se realizó la compra
- ▶ `Mall`: centro comercial donde se realizó la compra
- ▶ `Pago`: tipo de pago con el que se realizó la compra
- ▶ `Fecha`: fecha en la que se realizó la compra, en formato año, mes día
- ▶ `Código`: código interno del consorcio asociado al pago de la compra.

Elabore una tabla de frecuencias de las variables `Local`, `Mall` y `Pago`.
¿Cuántas categorías diferentes identifica? ¿Cuántas deberían ser?

Limpieza de texto: +DIVIDIRTEXTO

- ▶ Muchas veces los nombres o categorías vienen unidas por un *caracter*: símbolo slash (/), coma (,), punto y coma (;), guión (-), guión bajo (_) u otro caracter. ¿Cómo podemos hacer una separación rápida de los elementos?
- ▶ En la base de datos ventas, los nombres de los vendedores están todos separados por el guión bajo.
- ▶ Para separar el nombre del apellido, podemos hacer uso de la función:

+DIVIDIRTEXTO(texto ; delimitador)

Esto va a dividir la columna en dos, indicando en una lo que va antes y en otra lo que va después del guión bajo.

Ejemplo

- ▶ En la base de datos, agregue dos columnas a la derecha de la columna Nombre_Apellido.
- ▶ Aplicamos la función a la celda A2 indicando que el separador es guión bajo y apretamos ENTER.
- ▶ Arrastramos la función para que se aplique en todas las filas.

Nombre_Apellido		Nombre_Apellido		
Priscilla_Welch	+DIVIDIRTEXT(A2;"_")	Priscilla_Welch	Priscilla	Welch
Cole_Bray	DIVIDIRTEXT(text; col_delimiter;	Cole_Bray	Cole	Bray
Talia_Cuevas		Talia_Cuevas	Talia	Cuevas
Draven_Meyer		Draven_Meyer	Draven	Meyer

Ejercicio:

Ponga Nombre y Apellido como nombre de las columnas que se generan al aplicar la función anterior.

Limpieza de texto: UNIRCADENAS

Por el contrario, si se quiere hacer el proceso inverso: unir categorías mediante un caracter especial, podemos usar la función

`UNIRCADENAS(delimitador; ignorar_varías; texto1; texto2; ...)`

Así, podemos reconstruir la columna Nombre_Apellido de la base a partir de las dos columnas que generamos anteriormente.

Nombre	Apellido	
Priscilla	Welch	Priscilla Welch

➡

Nombre	Apellido	
Priscilla	Welch	Priscilla Welch

`UNIRCADENAS(delimitador; ignorar_varías; texto1; [texto2]; [texto3]; [`

Obs: podemos obtener el mismo resultado haciendo uso de la función `CONCAT(texto1; texto2; texto3; ...)`

MAYUSC - MINUSC - NOMPROPIO - ESPACIOS

- ▶ Muchas veces los nombres o categorías están escritos de diferentes maneras: mayúsculas, minúsculas, espacios intermedios, etc.
- ▶ Para unificar las categorías existen algunas funciones útiles como:
 - ▶ MAYUSC(texto): escribe texto completamente en mayúsculas.
 - ▶ MINUSC(texto): escribe texto completamente en minúsculas.
 - ▶ NOMPROPIO(texto): escribe en mayúscula cada inicio de palabra en texto.
 - ▶ ESPACIOS(texto): quita espacios iniciales y terminales en texto. Además deja solo un espacio entre palabras.

Ejemplo

Tienda	
PaRiS	=MAYUSC(B2)
JUMBo	MAYUSC(texto)



Tienda	
PaRiS	PARIS
JUMBo	

Tienda	
PaRiS	=MINUSC(B2)
JUMBo	MINUSC(texto)



Tienda	
PaRiS	paris
JUMBo	

Tienda		Ciudad
santa isabel	=NOMPROPIO(B13)	
easy	NOMPROPIO(texto)	



Tienda		Ciudad
santa isabel	Santa Isabel	
easy		

Tarjeta de Pago	
American Express	=ESPACIOS(D2)
Mastercard	ESPACIOS(texto)



Tarjeta de Pago	
American Express	American Express
Mastercard	

Ejercicio:

Utilice las funciones necesarias para estandarizar las categorías de Mall y Pago. Nombre estas variables como Mall final y Pago final.

Extraer texto: IZQUIERDA - DERECHA - EXTRAER

- ▶ Algunas funciones de excel son útiles para extraer parte una celda que tiene texto. Algunas de estas funciones son:
 - ▶ `IZQUIERDA(texto; núm_caracteres)`: extrae los primeros caracteres de texto.
 - ▶ `DERECHA(texto; núm_caracteres)`: extrae los últimos caracteres de texto.
 - ▶ `EXTRAER(texto; posición inicial; núm. caracteres)`: extrae, desde posición inicial, la cantidad de caracteres solicitados.
 - ▶ `REEMPLAZAR(texto; posición_inicial; núm_caracteres; nuevo_texto)`:

Ejemplo

Código	
RET242	+IZQUIERDA(F2;3
AUX450	IZQUIERDA(texto; [núm_de_caracteres])



Código	
RET242	RET
AUX450	

Código	
RET242	+DERECHA(F2;3
AUX450	DERECHA(texto; [núm_de_caracteres])



Código	
RET242	242
AUX450	

Código	
RET242	+EXTRAE(F2;4;3
AUX450	EXTRAE(texto; posición_inicial; núm_de_caracteres)



Código	
RET242	242
AUX450	

Código	
RET242	+REEMPLAZAR(F2;1;3;"ret"
AUX450	REEMPLAZAR(texto_original; núm_inicial; núm_de_caracteres; texto_nuevo)



Código	
RET242	ret242
AUX450	

Ejercicio:

Utilice estas funciones para separar las letras de los números de la variable Código.

Funciones lógicas

- ▶ Son aquellas funciones en que se evalúa si se cumple una condición o no.
- ▶ Algunas de estas funciones son:
 - ▶ `ESNUMERO(valor)`: verifica si `valor` es un número.
 - ▶ `ESTEXTO(valor)`: verifica si `valor` es texto.
 - ▶ `ESBLANCO(valor)`: verifica si `valor` representa una celda con dato faltante.

El resultado es VERDADERO o FALSO si es que se cumple o no la condición evaluada.

Ejercicio:

Utilice estas funciones para evaluar si las columnas obtenidas de la separación de la variable Código son de tipo número o texto.

Funciones lógicas: O - Y

Los operadores lógicos O e Y permiten evaluar si en una celda se cumplen dos o más condiciones (Y) o bien si al menos una de ellas se cumple (O).

Las evaluaciones lógicas se pueden hacer sobre una misma celda o más de una de ellas.

Mall final	Pago final	
Mall Plaza	Mastercard	+Y(G2="Mall Plaza";H2="Mastercard
Cenco Mall	Mastercard	Y(valor_lógico1; [valor_lógico2];



Mall final	Pago final	
Mall Plaza	Mastercard	VERDADERO
Cenco Mall	Mastercard	

Mall final	Pago final	
Mall Plaza	Mastercard	+O(G2="Cenco Mall";G2="Portal Plaza"
Cenco Mall	Mastercard	O(valor_lógico1; [valor_lógico2]; [v



Mall final	Pago final	
Mall Plaza	Mastercard	FALSO
Cenco Mall	Mastercard	

Condicionales: SI-SI.CONJUNTO

- ▶ Permiten evaluar una condición lógica y entrega el resultado especificado si la condición se cumple y también en caso de que no se cumpla.

`SI(condición; valor_si_verdadero; valor_si_falso)`

donde:

- ▶ `condición` es la expresión que se evalúa.
- ▶ `valor_si_verdadero` es el valor devuelto si la condición es verdadera.
- ▶ `valor_si_falso` es el valor devuelto si la condición es falsa.

Ejercicio:

Utilice esta función para crear la columna Mastercard en donde se especifique el valor 1 si Pago final es Mastercard y 0 en otro caso.

SI.CONJUNTO

Se utiliza como extensión de la función SI para evaluar más de una condición lógica a la vez

```
SI.CONJUNTO(condición1; valor_si_verdadero1;  
            condición2; valor_si_verdadero2;...)
```

donde:

- ▶ condición1 condición lógica 1
- ▶ valor_si_verdadero1 es el valor si la condición 1 se cumple.
- ▶ Ídem para las siguientes condiciones lógicas

Ejercicio

Utilice funciones lógicas y condicionales para crear la columna Pago_cat en donde se especifique:

- ▶ Pago_Cat = 1 si Pago final es Mastercard
- ▶ Pago_Cat = 2 si Pago final es Visa
- ▶ Pago_Cat = 3 si Pago final es American Express
- ▶ Pago_Cat = 4 si Pago final es Efectivo o Débito.

Fechas

Las fechas en Excel se pueden manejar de diferente forma:

- ▶ DD/MM/AA
- ▶ MM/DD/AA,

entre otras.

Del mismo modo, también podemos extraer el día, el mes y el año de la fecha en caso de que sea necesario.

Con la función FECHA(año;mes;día) podemos construir una celda con la fecha especificada. Po ejemplo:

+FECHA(2021;3;15)

nos entrega como fecha el día 15 de marzo de 2021.

¿Cómo trabajamos con las fechas cuando éstas vienen en una base de dato?

Ejemplo


La variable Fecha de la base de dato con la que estamos trabajando muestra la fecha en formato AAAAMMDD, sin embargo Excel no lo entiende como una fecha.

Para especificarle a Excel que la información de la columna es una fecha, vamos a utilizar la operación Texto en Columnas.

Seleccionamos la columna de fecha y vamos

Texto en Columnas -> Siguiente -> Fecha (especificar
formato) -> Finalizar

Ejemplo



ermite que "Microsoft AutoUpdate" se ejecute en segundo plano.

E

Fecha

20211017

20210418

20211030

20210723

20210126

20210603

20210907

20210509

20210307

20210430

20211226

20210303

20210705

20211211

20211027

20210102

20210327

20210917

20210222

20210116

20210320

20210228

20211018

Asistente para convertir texto en columnas - paso 1 de 3

El asistente estima que tus datos son Delimitados.

Si esto es correcto, elige Siguiente, o bien elige el tipo de datos que mejor los describa.

☒ Delimitados - Caracteres como comas o tabulaciones separan campos.

☐ De ancho fijo - Los campos están alineados en columnas con espacios entre uno y otro.

Vista previa de los datos seleccionados:

Vista previa de los datos seleccionados:

2 20211017

3 20210418

4 20211030

5 20210723

6 20210126

7 20210603

8 20210907

9 20210509

Cancelar


< Atrás

Siguiente >


Finalizar

20 / 26


Ejemplo




ermite que "Microsoft AutoUpdate" se ejecute en segundo plano.



Ejemplo



ermite que "Microsoft AutoUpdate" se ejecute en segundo plano.



Ejemplo

El resultado es la fecha separada según el formato especificado.

Fecha	I
17-10-21	
18-04-21	
30-10-21	
23-07-21	
26-01-21	
03-06-21	
07-09-21	
09-05-21	
07-03-21	
30-04-21	
26-12-21	
03-03-21	
05-07-21	

Fechas

Una vez que está especificada correctamente la fecha en Excel, podemos extraer de la fecha información específica con las funciones:

- ▶ `DIA(num_de_serie)`: número del día
- ▶ `MES(num_de_serie)`: número del mes
- ▶ `AÑO(num_de_serie)`: número del año

Ejercicio:

Construya las columnas Día, Mes y Año en donde especifique el día, el mes y el año asociado a todas las compras de las que se tiene información en la base de datos `compras.xls`

Tarea

- ▶ A partir de las columnas Día, Mes y Año reconstruya la fecha de la compra en formato AA/MM/DD. Asegúrese de que el resultado quede en formato de fecha.
- ▶ Pruebe que el resultado obtenido haciendo uso de la función DIVIDIRTEXTO que aplicamos en la clase es el mismo que se obtiene al aplicar la opción
 Texto en columnas -> Delimitador: especificar en
 ‘Otro’ símbolo guión bajo _ -> Siguiente ->
 Finalizar

Tarea

- ▶ Apoyándose en las funciones vistas en esta clase:
 1. Calcule cuántas compras se hicieron en al menos un supermercado (Jumbo, Santa Isabel) y en un Cenco Mall.
 2. ¿Cuántas compras se hicieron posterior al 1 de abril de 2026?
Hint: las operaciones lógicas también se pueden aplicar sobre fechas. Para ello especifique la fecha 01-04-2026 en una celda cualquiera (fuera de la base) y aplique alguna operación lógica que sea de utilidad.