

Laboratorio 14 - Preprocesamiento de bases de datos

Daniel Saavedra y Mauricio Toro

Departamento de Estadística
Pontificia Universidad Católica de Chile

Martes 12 de mayo, 2026



Contenidos

Motivación

Datos faltantes

Datos duplicados

Ejercicio

Base de datos

La base de datos `estudiantes.xlsx` contiene información sobre un grupo de estudiantes que ingresaron a la educación superior.

- ▶ `MRUN`: Identificador único de cada estudiante.
- ▶ `EDAD`: Edad al momento del ingreso.
- ▶ `SEXO`: Indica el sexo de cada estudiante.
- ▶ `COD_DEPE`: Tipo de dependencia del establecimiento escolar:
 1. Municipal,
 2. Particular Subvencionado,
 3. Particular Pagado.
- ▶ `NEM`: Nota de Enseñanza Media.
- ▶ `PROMEDIO`: Promedio general obtenido en el primer año de universidad.

Realice una exploración visual de la base de datos. ¿Qué observaciones puede hacer a partir de ella?

¿Qué es el preprocesamiento de datos?

- ▶ El preprocesamiento de datos es el conjunto de tareas necesarias para preparar un conjunto de datos antes de realizar análisis estadísticos o modelos predictivos.
- ▶ Incluye actividades como: limpieza (Lab12), manejo de datos faltantes, detección de valores duplicados, entre otras.

¿Qué son los datos faltantes?

- ▶ Es una observación que no está disponible o no ha sido registrada en una o más variables de un conjunto de datos.
- ▶ Son frecuentes en datos reales: encuestas, registros administrativos, sensores, etc.
- ▶ Algunos ejemplos comunes son:
 - ▶ Un encuestado omite una pregunta sensible.
 - ▶ Un sensor no registra temperatura por falla técnica.
 - ▶ Una variable no fue medida en una parte del estudio.

Mecanismos de omisión

Rubin (1976) en su artículo *Inference and Missing Data* propuso una clasificación ampliamente utilizada según el mecanismo de omisión:

- ▶ **MCAR** (*Missing Completely At Random*): la omisión es completamente arbitraria.
- ▶ **MAR** (*Missing At Random*): la omisión depende de otras variables observadas.
- ▶ **MNAR** (*Missing Not At Random*): la omisión depende del valor que falta.

Ejemplos de mecanismos de omisión

MCAR (*Missing Completely At Random*)

Se pierden encuestas de forma **aleatoria** debido a un fallo en el sistema de almacenamiento, **sin relación con las variables observadas ni no observadas**.

MAR (*Missing At Random*)

El ingreso no es reportado con mayor frecuencia en personas **jóvenes**, pero **dentro de cada grupo de edad la omisión es aleatoria**.

MNAR (*Missing Not At Random*)

Las personas con mayores ingresos tienden a no declarar su salario, por lo que **la omisión depende del propio valor faltante**.

Opciones básicas para tratar datos faltantes

Algunas estrategias simples para imputar datos faltantes incluyen:

- ▶ **Eliminación de observaciones:** apropiada si la proporción de datos faltantes es pequeña.
- ▶ **Imputación:** consiste en reemplazar los valores faltantes por sus estimaciones.
 - ▶ **Valor constante:** como la media, mediana o moda.
 - ▶ **Basada en otras variables:** modelo de regresión.

Imputación con la media

- ▶ Consiste en reemplazar los valores faltantes con la media de la variable, calculada a partir de los datos observados.
- ▶ Es una técnica sencilla y rápida, pero tiende a reducir artificialmente la variabilidad.
- ▶ Es recomendable cuando la omisión de los datos es completamente al azar.

Ejemplo:

$$X = \{5, 7, \text{NA}, 6, 8\} \Rightarrow \bar{X}_{\text{obs}} = \frac{5 + 7 + 6 + 8}{4} = 6.5,$$

$$\text{Imputación: } X^* = \{5, 7, \mathbf{6.5}, 6, 8\}$$

¿Cuál es la media del conjunto con imputación? ¿Qué efecto tuvo la imputación sobre la varianza?

Imputación por regresión

- ▶ Utiliza un modelo de regresión para estimar los valores faltantes a partir de otras variables del conjunto de datos.
- ▶ Aprovecha las relaciones entre variables y suele ser más precisa que la imputación con la media.
- ▶ Sin embargo, la regresión genera un valor único para cada dato faltante, el cual sería su valor esperado según el modelo, pero no refleja la incertidumbre inherente a la estimación.

Ejemplo:

Si falta Y , pero se conoce la relación $Y = \beta_0 + \beta_1 X + \epsilon$,
entonces la imputación se realiza como: $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$

Buenas prácticas al tratar valores perdidos

- ▶ Diagnosticar el patrón y porcentaje de omisión.
- ▶ Evitar imputaciones arbitrarias sin justificación.
- ▶ Reportar siempre cómo se manejaron los datos faltantes.

¿Qué son los datos duplicados?

- ▶ Se consideran datos duplicados aquellos registros que aparecen más de una vez en el conjunto de datos.
- ▶ Su aparición puede deberse a errores de digitación o fallos en los sistemas de recolección.
- ▶ Su presencia puede introducir sesgos, inflar el tamaño muestral y comprometer la validez de los análisis estadísticos.

Ejemplos de duplicación


- ▶ **Duplicado exacto:** la fila completa se repite sin modificaciones.
- ▶ **Duplicado parcial:** se repiten valores en algunas columnas aunque otras puedan diferir.

Ejemplo:

ID	Edad	Altura
001	25	1.70
002	30	1.80
001	25	1.70
003	30	1.80
004	20	1.50
005	35	1.85

¿Cómo detectar valores duplicados?

- ▶ En Excel, esta tarea se puede realizar seleccionando Formato condicional y luego aplicando una Regla para resaltar las celdas -> Valores duplicados....




¿Qué hacer con los duplicados?

- ▶ **Eliminar duplicados exactos:** es una práctica habitual cuando toda la fila se repite de forma idéntica, especialmente si se tiene certeza de que corresponde al mismo individuo.
- ▶ **Revisar duplicados parciales:** si se deben a errores de digitalización o integración, conviene eliminarlos o corregirlos.
- ▶ **Agrupar o resumir:** en casos con múltiples registros del mismo individuo, puede ser útil consolidar la información (por ejemplo, usando promedios o la última medición).

Eliminar duplicados

En Excel, los duplicados pueden eliminarse seleccionando Quitar duplicados en la pestaña Datos, aquí se puede especificar qué columnas se utilizarán para identificar las filas repetidas.



Buenas prácticas al tratar duplicados

- ▶ Verificar cuidadosamente qué variables se utilizan para identificar duplicados, especialmente en casos de duplicados parciales.
- ▶ Documentar los criterios aplicados para decidir la eliminación o conservación de registros.
- ▶ Conservar una copia del conjunto de datos original antes de realizar cualquier modificación irreversible.

¡Manos a la obra! (Parte I)

1. Detecte los registros duplicados exactos en la base.
2. Decida si deben mantenerse o eliminarse. Justifique su decisión.
3. Utilizando un formato condicional, agregue una barra de datos a la variable NEM.
4. Utilizando un formato condicional, aplique una regla para resaltar a los estudiantes cuyo PROMEDIO se encuentre dentro del 10% superior.
5. Utilizando un formato condicional, resalte a los estudiantes provenientes de colegios particulares subvencionados.
6. Aplique una escala de colores a la variable PROMEDIO para visualizar su distribución.

¡Manos a la obra! (Parte II)

7. Reporte cuántos valores perdidos hay en cada columna.
8. Identifique el tipo de mecanismo de omisión en las variables con datos faltantes.
9. Proponga un método de imputación para cada caso.
10. Realice un análisis descriptivo breve, considerando la información disponible tras el tratamiento de datos.