

Laboratorio 15 - Introducción a las bases de datos

Daniel Saavedra y Mauricio Toro

Departamento de Estadística
Pontificia Universidad Católica de Chile

Martes 26 de mayo, 2026



Contenidos

Motivación

Modelos de Datos

Sistemas de bases de datos (DBMS)

Bases de datos relacionales

Bases de datos en Excel

Durante todo el semestre hemos trabajado con datos en Excel. Hemos visto que este programa es útil para:

- ▶ Almacenar datos.
- ▶ Realizar cálculos.
- ▶ Calcular estadísticos.
- ▶ Hacer gráficos.

Bases de datos en Excel

¿Qué información contiene el documento Excel? (hacer zoom)

	A	B	C	D	E	F	G	H	I
1	inscripcion id	nombre estudiante	genero estudiante	direccion estudiante	asignatura id	nombre asignatura	creditos	nombre profesor	nota final
2	40	Juan Sepúlveda Sepúlveda	Masculino	Gran Avenida 1584, Santiago	116	Biología	6	Fernanda Soto Soto	2
3	63	Juan Sepúlveda Sepúlveda	Masculino	Gran Avenida 1584, Santiago	109	Historia	6	Felipe Silva Pérez	2,6
4	177	Juan Sepúlveda Sepúlveda	Masculino	Gran Avenida 1584, Santiago	102	Econometría	3	Matías Pérez Muñoz	4,4
5	224	Juan Sepúlveda Sepúlveda	Masculino	Gran Avenida 1584, Santiago	114	Física	4	María González Sepúlveda	2,8
6	77	Ignacio Contreras González	Masculino	Gran Avenida 4291, Santiago	111	Programación	3	Felipe Silva Silva	3,2
7	195	Ignacio Contreras González	Masculino	Gran Avenida 4291, Santiago	109	Historia	6	Felipe Silva Pérez	6,7
8	198	Ignacio Contreras González	Masculino	Gran Avenida 4291, Santiago	104	Álgebra	3	Diego Díaz Contreras	4,6
9	83	Javier Contreras Díaz	Masculino	Av. Recoleta 1822, Santiago	101	Estadística	5	Nicolás Sepúlveda Rojas	6,8
10	141	Javier Contreras Díaz	Masculino	Av. Recoleta 1822, Santiago	102	Econometría	3	Matías Pérez Muñoz	2,9
11	186	Javier Contreras Díaz	Masculino	Av. Recoleta 1822, Santiago	118	Antropología	5	Antonia Martínez Muñoz	3,9
12	17	Antonia Muñoz Sepúlveda	Femenino	Av. Recoleta 1697, Santiago	111	Programación	3	Felipe Silva Silva	3,8
13	18	Antonia Muñoz Sepúlveda	Femenino	Av. Recoleta 1697, Santiago	105	Probabilidad	4	Nicolás Pérez Rojas	4,8
14	131	Antonia Muñoz Sepúlveda	Femenino	Av. Recoleta 1697, Santiago	101	Estadística	5	Nicolás Sepúlveda Rojas	4,6
15	152	Antonia Muñoz Sepúlveda	Femenino	Av. Recoleta 1697, Santiago	118	Antropología	5	Antonia Martínez Muñoz	5,8
16	244	Antonia Muñoz Sepúlveda	Femenino	Av. Recoleta 1697, Santiago	115	Química	3	Nicolás González Díaz	5,3
17	32	Antonia Díaz Sepúlveda	Femenino	Gran Avenida 3402, Santiago	118	Antropología	5	Antonia Martínez Muñoz	4,1
18	41	Antonia Díaz Sepúlveda	Femenino	Gran Avenida 3402, Santiago	104	Álgebra	3	Diego Díaz Contreras	2,3
19	167	Antonia Díaz Sepúlveda	Femenino	Gran Avenida 3402, Santiago	111	Programación	3	Felipe Silva Silva	4
20	191	Antonia Díaz Sepúlveda	Femenino	Gran Avenida 3402, Santiago	108	Ética	3	Felipe Silva Pérez	3,3
21	239	Antonia Díaz Sepúlveda	Femenino	Gran Avenida 3402, Santiago	102	Econometría	3	Matías Pérez Muñoz	5
22	295	Antonia Díaz Sepúlveda	Femenino	Gran Avenida 3402, Santiago	109	Historia	6	Felipe Silva Pérez	4,4
23	4	Juan Martínez Martínez	Masculino	Gran Avenida 1382, Santiago	120	Filosofía	6	María Muñoz Pérez	3,6
24	116	Juan Martínez Martínez	Masculino	Gran Avenida 1382, Santiago	119	Derecho	4	María Martínez González	2,2
25	147	Juan Martínez Martínez	Masculino	Gran Avenida 1382, Santiago	104	Álgebra	3	Diego Díaz Contreras	6,1
26	154	Juan Martínez Martínez	Masculino	Gran Avenida 1382, Santiago	110	Lenguaje	5	Nicolás Silva Pérez	3
27	188	Juan Martínez Martínez	Masculino	Gran Avenida 1382, Santiago	117	Sociología	5	Antonia Martínez Muñoz	6,1
28	271	Juan Martínez Martínez	Masculino	Gran Avenida 1382, Santiago	119	Derecho	4	María Martínez González	4,7

Excel: algunas limitaciones

- ▶ ¿Qué pasa si tengo más de 1.048.576 inscripciones?
- ▶ ¿Qué pasa si cambia la dirección de Juan Sepúlveda Sepúlveda?
- ▶ No es eficiente repetir muchas veces el mismo valor.
 - ▶ Podríamos ahorrar memoria codificando las categorías.
 - ▶ Pero se volvería engorroso trabajar en Excel con tanto BUSCARV

Más allá de Excel

Es momento de ir más allá de Excel. Para eso, primero debemos conocer qué es un **modelo de datos**.

Modelo de datos: tablas


A lo largo del curso, hemos trabajado con datos representados como tablas. Por ejemplo, consideremos los datos de las siguientes cervezas:

Cervezas			
nombre	tipo	grados	ciudad-origen
Austral Lager	Lager	4,6	Punta Arenas
Austral Yagan	Ale	5,0	Punta Arenas
Austral Pale Ale	Ale	5,0	Punta Arenas
Kuntsmann Torobayo	Ale	5,1	Valdivia
Kross 5	Ale	7,2	Curacaví
Kross Golden	Ale	5,3	Curacaví
Kross Pilsner	Pilsner	4,9	Curacaví

Una tabla tiene una **estructura rígida**: para cada registro (fila) se especifican los mismos atributos (columnas).


Modelo de datos: árbol/jerararquía

Cuando existen jerarquías naturales en los datos, estos pueden ser representados mediante un árbol.




Modelo de datos: árbol/jerarquía

Pero ¿qué ubicamos más arriba en la jerarquía? No hay una representación única.



Modelo de datos: grafo

Otra forma de representar los datos es con grafos.



Comparación de modelos de datos

Tabla

- ▶ Modelo simple de entender.
- ▶ Modelo rígido: difícil de extender con nuevos atributos.
- ▶ Problemas con datos faltantes.

Árbol

- ▶ Modelo simple de entender.
- ▶ Modelo flexible.
- ▶ No admite repeticiones.
- ▶ Requiere una jerarquía implícita.

Grafo

- ▶ Modelo puede volverse complejo.
- ▶ Modelo muy flexible.
- ▶ No tiene un esquema obvio.
- ▶ Difícil de resumir.

Modelo de datos relacionales y no relacionales


- ▶ **Bases de datos relacionales:** Los elementos se organizan como un conjunto de tablas con columnas y filas. Tienen una llave (identificador) que permite relacionar los datos.
- ▶ **Bases de datos NO relacionales :** No poseen un identificador que permita relacionar los datos. Normalmente, la información es organizada por documentos y no necesariamente hay un esquema de lo que se almacenará.

¿Cuándo se utiliza cada una?

- ▶ **Relacionales:** El volumen de datos no crece rápidamente, el proceso de análisis se puede hacer en un solo servidor.
- ▶ **No Relacionales:** El volumen de datos crece muy rápido, los análisis requieren de más de un servidor (Twitter/X, Instagram, Facebook, Netflix, Amazon, Spotify, etc).

¿Cómo se almacenan los datos?

- ▶ Si tenemos una tabla, podemos almacenarla en un documento .csv o un Excel (.xlsx)
- ▶ Datos no relacionales pueden ser representados con árboles. Por ejemplo, considere una base con metadatos sobre los ganadores de premios Oscar:




Modelo de datos: árbol/jerarquía

En este caso, cada registro podría ser almacenado en un documento de texto (.json). por ejemplo:

```
<?xml version="1.0" encoding="UTF-8"?>
<bios>
  <person name="Mike Leigh">
    <dob>1943-02-20</dob>
    <nationality xml:lang="en">Great Britain</nationality>
    <award>
      <category xml:lang="en">Best Director</category>
      <event>Cannes</event>
      <year>1993</year>
      <movie>Naked</movie>
    </award>
    <award>
      <category xml:lang="fr">Palme d'Or</category>
      <event>Cannes</event>
      <year>1996</year>
      <movie>Secrets & Lies</movie>
    </award>
  </person>
  <person name="Julius Avery">
    ...
  </person>
  ...
</bios>
```

Sistemas de bases de datos (DBMS)

Se pueden definir como un tipo de software que sirve de interfaz entre el usuario y la información almacenada en una base de datos.



DBMS más usados (a la fecha)

DB-Engines Ranking

The DB-Engines Ranking ranks database management systems according to their popularity. The ranking is updated monthly.

Read more about the [method](#) of calculating the scores.



434 systems in ranking, May 2026

Rank			DBMS	Database Model	Score		
May 2026	Apr 2026	May 2025			May 2026	Apr 2026	May 2025
1.	1.	1.	Oracle	Relational, Multi-model	1143.28	-14.66	-83.29
2.	2.	2.	MySQL	Relational, Multi-model	856.49	-1.20	-108.49
3.	3.	3.	Microsoft SQL Server	Relational, Multi-model	700.99	-1.08	-73.90
4.	4.	4.	PostgreSQL	Relational, Multi-model	682.68	+1.33	+8.37
5.	5.	5.	MongoDB	Document, Multi-model	384.65	-0.37	-17.87
6.	6.	6.	Snowflake	Relational	215.64	-1.73	+43.63
7.	7.	↑ 12.	Databricks	Multi-model	151.79	+1.31	+49.13
8.	8.	↓ 7.	Redis	Key-value, Multi-model	147.63	+1.09	-4.56
9.	9.	↓ 8.	IBM Db2	Relational, Multi-model	113.04	-0.21	-13.36
10.	10.	↑ 11.	Apache Cassandra	Wide column, Multi-model	101.67	-0.95	-6.39
11.	11.	↓ 9.	Elasticsearch	Multi-model	96.02	-3.49	-27.79
12.	12.	↓ 10.	SQLite	Relational	95.88	-0.01	-21.89
13.	13.	↑ 14.	MariaDB	Relational, Multi-model	82.74	-3.67	-10.86
14.	↑ 15.	↑ 16.	Apache Hive	Relational	74.70	+0.57	-1.07
15.	↓ 14.	↑ 17.	Microsoft Azure SQL Database	Relational, Multi-model	73.34	-2.62	-2.11
16.	16.	↑ 18.	Splunk	Search engine	72.42	-0.66	+1.03
17.	17.	↓ 13.	Microsoft Access	Relational	62.30	-2.61	-33.60

Microsoft Access

En las siguientes clases trabajaremos con bases de datos relacionales usando el DBMS Microsoft Access.

Microsoft Access es un sistema de gestión de bases de datos relacionales (RDBMS) que forma parte del paquete Microsoft Office. Permite crear tablas, consultas, formularios e informes de manera visual, sin necesidad de escribir código SQL complejo. Es ideal para proyectos pequeños y medianos, así como para el aprendizaje de conceptos de bases de datos relacionales.

Datos en más de una tabla

Para entender la necesidad de múltiples tablas, consideremos el siguiente contexto: una universidad necesita almacenar información de sus estudiantes, las asignaturas que ofrece, sus profesores y las calificaciones obtenidas en las inscripciones.

Nombre	Año_ingreso	Asignatura	Profesor	Departamento	Nota
Antonia Díaz Sepúlveda	2023	Antropología	Antonia Martínez Muñoz	Ciencias Sociales	4,1
Antonia Díaz Sepúlveda	2023	Álgebra	Diego Díaz Contreras	Matemáticas	2,3
Antonia Díaz Sepúlveda	2023	Programación	Felipe Silva Silva	Computación	4,0
Antonia Díaz Sepúlveda	2023	Ética	Felipe Silva Pérez	Humanidades	3,3
Antonia Díaz Sepúlveda	2023	Econometría	Matías Pérez Muñoz	Economía	5,0
Antonia Díaz Sepúlveda	2023	Historia	Felipe Silva Pérez	Humanidades	4,4
Antonia González Silva	2023	Base de Datos	Felipe Silva Silva	Computación	3,9
Antonia González Silva	2023	Estadística	Nicolás Sepúlveda Rojas	Matemáticas	5,3
Antonia González Silva	2023	Econometría	Matías Pérez Muñoz	Economía	2,8
Antonia Muñoz Sepúlveda	2023	Programación	Felipe Silva Silva	Computación	3,8
Antonia Muñoz Sepúlveda	2023	Probabilidad	Nicolás Pérez Rojas	Matemáticas	4,8
Antonia Muñoz Sepúlveda	2023	Estadística	Nicolás Sepúlveda Rojas	Matemáticas	4,6
Antonia Muñoz Sepúlveda	2023	Antropología	Antonia Martínez Muñoz	Ciencias Sociales	5,8
Antonia Muñoz Sepúlveda	2023	Química	Nicolás González Díaz	Ciencias	5,3
Antonia Pérez Contreras	2024	Ética	Felipe Silva Pérez	Humanidades	2,0
Antonia Pérez Contreras	2024	Antropología	Antonia Martínez Muñoz	Ciencias Sociales	2,0
Antonia Pérez Contreras	2024	Derecho	María Martínez González	Derecho	5,0
Antonia Pérez Contreras	2024	Probabilidad	Nicolás Pérez Rojas	Matemáticas	3,6

Si usáramos una sola tabla, tendríamos repeticiones innecesarias!

Estructura de una tabla

Una tabla se compone de:

- ▶ **Registro (fila)**: cada instancia o elemento único. Ejemplo: un estudiante, un curso, una matrícula.
- ▶ **Atributo (columna)**: cada característica o propiedad del registro. Ejemplo: nombre, RUT, fecha de nacimiento.
- ▶ **Llave primaria (Primary Key)**: un atributo (o conjunto de atributos) que identifica de manera **única** cada registro. No puede repetirse ni estar vacío.

Ejemplo: Tabla Estudiantes

estudiante_id 🔑	nombre	genero	direccion	año_ingreso	sem_ingreso
1001	Juan Sepúlveda Sepúlveda	Masculino	Gran Avenida 1584	2023	1
1002	Ignacio Contreras González	Masculino	Gran Avenida 4291	2023	1
1003	Javier Contreras Díaz	Masculino	Av. Recoleta 1822	2023	1
1004	Antonia Muñoz Sepúlveda	Femenino	Av. Recoleta 1697	2023	1
1005	Antonia Díaz Sepúlveda	Femenino	Gran Avenida 3402	2023	1

Aquí `estudiante_id` es la llave primaria 🔑.

Relación con otras tablas

Para conectar tablas entre sí se utiliza una **llave foránea (Foreign Key)**. Una llave foránea es un atributo en una tabla que hace referencia a la llave primaria de otra tabla.

Ejemplo: Tabla Inscripciones se relaciona con Estudiantes y Asignaturas.

inscripcion_id 🔑	estudiante_id 🔑	asignatura_id 🔑	nota_final
1	1088	115	7
2	1069	104	4,8
3	1034	113	4,4

Los valores en `estudiante_id` deben existir previamente en `Estudiantes.estudiante_id`. De igual forma, `asignatura_id` debe existir en `Asignaturas.asignatura_id`.

Datos de ejemplo

Los datos de ejemplo ilustrados anteriormente están contenidos en el archivo Lab15.xlsx.

Estudiantes

- ▶ estudiante_id
- ▶ nombre
- ▶ genero
- ▶ direccion
- ▶ año_ingreso
- ▶ semestre_ingreso

Inscripciones

- ▶ inscripcion_id
- ▶ estudiante_id
- ▶ asignatura_id
- ▶ nota_final

Asignaturas

- ▶ asignatura_id
- ▶ nombre_asignatura
- ▶ creditos
- ▶ profesor_id

Profesores

- ▶ profesor_id
- ▶ nombre
- ▶ genero
- ▶ direccion
- ▶ departamento

Ventajas de representar datos en múltiples tablas

Utilizar múltiples tablas relacionadas ofrece importantes beneficios:

- ▶ **Ahorro de memoria:** se evita repetir información (por ejemplo, los datos de un estudiante aparecen una sola vez).
- ▶ **Consistencia:** si un estudiante cambia de nombre, solo se modifica en una tabla; no hay riesgo de datos inconsistentes.
- ▶ **Orden y claridad:** cada tabla contiene un tipo de entidad bien definido, facilitando la comprensión y el mantenimiento.
- ▶ **Flexibilidad:** es más fácil agregar nuevos atributos (ej. teléfono del estudiante) sin afectar al resto de las tablas.
- ▶ **Seguridad:** se pueden otorgar permisos (lectura y escritura) diferenciados por tabla.

Consulta

Una **consulta** es una pregunta que le hacemos a la base de datos para obtener información específica, sin modificar los datos originales. Las consultas permiten:

- ▶ Filtrar registros (ej. estudiantes de una carrera).
- ▶ Ordenar resultados (ej. por nota descendente).
- ▶ Calcular nuevos valores (ej. promedio de notas).
- ▶ Combinar datos de varias tablas.

Ejemplo: “Mostrar el nombre y año_ingreso de los estudiantes que ingresaron el año 2024”. La base de datos examina la tabla Estudiantes, aplica el filtro (`año_ingreso = 2024`) y devuelve solo las filas que cumplen la condición.

Consulta: Join

A menudo necesitamos información que reside en **dos o más tablas** relacionadas. La operación que combina tablas se llama **Join** (combinación o enlace).

Ejemplo: Queremos un listado que muestre el nombre del estudiante, el nombre_asignatura y su nota_final. Los datos están distribuidos así:

- ▶ Estudiantes → nombre, estudiante_id
- ▶ Asignaturas → nombre_asignatura, asignatura_id
- ▶ Inscripciones → estudiante_id, asignatura_id, nota_final

Haciendo un *Join* entre estas tres tablas usando las llaves (estudiante_id y asignatura_id), podemos obtener una única vista con toda la información:

nombre	nombre_asignatura	nota_final
Sofía Muñoz González	Química	7
María Rojas Contreras	Álgebra	4,8
Diego Soto Sepúlveda	Inteligencia Artificial	4,4

¡Manos a la obra!

Practicaremos los conceptos vistos en Excel. Para esto, considere los datos contenidos en el archivo `Lab15.xlsx`.

- ▶ Para cada tabla, indique cuál es la llave primaria.
- ▶ ¿Existen registros con llave primaria duplicada?
- ▶ ¿Qué tablas tienen llaves foráneas?

Entregue el resultado de las siguientes consultas:

- ▶ ¿Qué estudiantes ingresaron el año 2024?
- ▶ ¿Cuántos estudiantes hay por género?
- ▶ ¿Qué profesores pertenecen al departamento de Ciencias?
- ▶ ¿Cuántos créditos tiene cada asignatura?

Función BUSCARX en Excel

¿Qué hace BUSCARX?

- ▶ Es parte de la nueva generación de funciones de Excel. Vino a reemplazar/mejorar el archifamoso y legendario BUSCARV.
- ▶ Permite buscar un valor en una tabla o rango.
- ▶ Puede buscar hacia la izquierda, derecha, arriba o abajo.
- ▶ Lo usaremos para hacer “Join” en Excel.

Sintaxis básica:

`=BUSCARX(valor_buscado, matriz_busqueda, matriz_resultado)`

Ejemplo

`=BUSCARX(3;$Profesores.A:A;$Profesores.B:B)`

Busca el id de profesor = 3 en la tabla Profesores y devuelve el nombre asociado.

¡Manos a la obra!

Cree las tablas que respondan cada una de las siguientes consultas:

- ▶ ¿Qué asignatura(s) dicta cada profesor?
- ▶ ¿Qué asignaturas cursa el estudiante **Diego Silva Sepúlveda**?
- ▶ ¿Qué nota obtuvo el estudiante **Felipe Martínez Díaz** en **Macroeconomía**?
- ▶ ¿Qué estudiantes aprobaron una asignatura?
- ▶ ¿Cuál es el promedio de notas de cada asignatura?
- ▶ ¿Qué profesores tienen más estudiantes inscritos?
- ▶ ¿Qué estudiantes cursan asignaturas del departamento de **Ciencias**?

Excel no es para hacer consultas

Como pudimos ver, el uso de Excel se torna tedioso para responder consultas.

Si es que queremos hacer consultas a bases de datos ¡Excel es el software equivocado! En la próxima clase comenzaremos a trabajar en MS Access.

Moraleja

Excel es muy útil, pero no todo se debería hacer en Excel. Si solo tenemos un martillo, querremos arreglarlo todo a martillazos.