
Ayudantía 6 — Métodos Bayesianos II (EYP3207)

Ayudante: Daniel Saavedra
Profesores: Fernando Quintana

Pontificia Universidad Católica de Chile
Facultad de Matemáticas

Paquetes a Utilizar :

```
install.packages("mclust")  
install.packages("sf")  
install.packages("mapview")
```

Modelo de Mixturas Gaussianas

Un modelo de mixturas gaussianas es un modelo probabilístico que asume que los datos son generados a partir de una combinación de varias distribuciones normales (gaussianas) con diferentes medias y varianzas. La densidad de probabilidad de un modelo de mixtura gaussiana se define como:

$$p(\mathbf{x}|\boldsymbol{\theta}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k), \quad (1)$$

donde:

- $\mathbf{x} \in \mathbb{R}^d$ es un vector de datos de dimensión d .
- K es el número de componentes en la mixtura.
- π_k es el peso de la k -ésima componente, con $\sum_{k=1}^K \pi_k = 1$ y $\pi_k \geq 0$.
- $\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$ es la densidad de la distribución normal multivariada con media $\boldsymbol{\mu}_k$ y matriz de covarianza $\boldsymbol{\Sigma}_k$, definida como:

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}_k|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}_k^{-1}(\mathbf{x} - \boldsymbol{\mu}_k)\right). \quad (2)$$

El vector de parámetros del modelo se denota por $\boldsymbol{\theta} = \{\pi_k, \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k\}_{k=1}^K$.

Para ajustar el modelo a los datos, generalmente se utiliza el algoritmo de Expectation-Maximization (EM).

Utilizaremos la librería **mclust** la cual realiza dicho ajuste.

Ejemplo 1

1. Generar 5 observaciones de una normal con bivariada con media $\mu = (0, 0)$ y varianza $\Sigma = \text{diag}(0, 4, 0, 4)$. Generar 5 observaciones de una normal con bivariada con media $\mu = (2, 2)$ y varianza $\Sigma = \text{diag}(0, 4, , 4)$. Grafique los puntos.
2. Utilizar la función *Mclust()* para estimar los parámetros de la mixtura.
3. Analizar los distintos modelos ajustados y compare su BIC (*mclustBIC*).
4. Gráfique la densidad estimada de la mixtura, pero utilizando solamente 2 componentes ($G = 2$).
5. Analizar los resultados utilizando las siguientes configuraciones de la priori:
 - a) $\mu_0 = (100, 100)$ y $\Sigma = \text{diag}(2, 10)$.
 - b) Priori solo para el parámetro de escala $\Sigma = \text{diag}(2, 10)$.
6. Replicar el análisis anterior pero ahora con una muestra de 50 observaciones de la primera distribución y 10 observaciones para la segunda distribución.

Ejercicio 1 Old Faithful Geyser

En la base de datos *faithful* nos muestra 272 observaciones del tiempo de espera entre erupciones y duración de la erupción del géiser Old Faithful en el Parque Nacional Yellowstone, Wyoming, EE.UU.

1. Gráfique los datos en 2 dimensiones. ¿Se aprecia algún patrón?
2. Utilizar la función *Mclust()* para estimar los parámetros de la mixtura.
3. Analizar los distintos modelos ajustados y compare su BIC (*mclustBIC*).
4. Analizar los resultados utilizando las siguientes configuraciones de la priori:
 - a) $\mu_0 = (100, 100)$ y $\Sigma = \text{diag}(1, 1)$.
 - b) Priori solo para el parámetro de escala. $\Sigma = \text{diag}(1, 1)$.

Ejercicio 2 Atropellos en Santiago Centro 2017

En la base de datos *entregadas* existe 139 observaciones de los puntos geográficos (longitud, latitud) y la cantidad de siniestro en dicho lugar. Queremos analizar si es posible agrupar dichos atropellos por sector y cuántos sectores serían los ideales para llevar a cabo la separación.

1. Graficar los datos mediante la función *mapview()*.
2. Por cada punto geográfico genere una observación por la cantidad de siniestros en esa ubicación.
3. Utilizar la función *Mclust()* para estimar los parámetros de la mixtura.
4. Analizar los resultados obtenidos.
5. Graficar los datos con la clasificación de su ubicación. Comente los resultados.