
Ayudantía 7 — Métodos Bayesianos II (EYP3207)

Ayudante: Daniel Saavedra

Pontificia Universidad Católica de Chile

Profesores: Fernando Quintana

Facultad de Matemáticas

Paquetes a Utilizar :

```
install.packages("mixtools")
```

Modelo de Mezclas Gaussianas (GMM) EM

Un Modelo de Mezclas Gaussianas (GMM) es una combinación de varias distribuciones normales (gaussianas) que pueden modelar una distribución más compleja de datos. Matemáticamente, se puede expresar como:

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x|\mu_k, \Sigma_k) = \prod_{k=1}^K \pi_k^{I(z=k)} \mathcal{N}(x|\mu_k, \Sigma_k)^{I(z=k)}$$

EM

La función log-verosimilitud completa:

$$\log L(\pi, \mu, \Sigma) = \sum_{i=1}^N \sum_{k=1}^K I(z_i = k) \log (\pi_k \mathcal{N}(x_i|\mu_k, \Sigma_k))$$

E-step: En este paso, calculamos la responsabilidad $\gamma(z_{ik})$ de que el punto de datos x_i provenga del componente k :

$$\mathbb{E}(I(z_i = k)) = \gamma(z_{ik}) = \frac{\pi_k \mathcal{N}(x_i|\mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_i|\mu_j, \Sigma_j)}$$

M-step:

$$\operatorname{argmax}(Q(\theta|\theta^{(t)})) = \operatorname{argmax}\left(\sum_{i=1}^N \sum_{k=1}^K \gamma^{(t)}(z_{ik}) \log (\pi_k \mathcal{N}(x_i|\mu_k, \Sigma_k))\right)$$

Mixtura de Gammas

Esbozar el algoritmo EM para una mezcla de distribuciones Gammas. Encuentre las similitudes y diferencias del GMM.

Ejemplo 1

1. Generar 50 observaciones de una gamma con parámetros $\alpha = 2$ y $\sigma = 1$. Generar 50 observaciones de una segunda gamma con parámetros $\alpha = 5$ y $\sigma = 2$. Generar 50 observaciones de una tercera gamma con parámetros $\alpha = 9$ y $\sigma = 3$.
2. Utilizar la función `gammamixEM()` para estimar los parámetros de la mixtura, compare la estimación para $k = 2$ y $k = 3$.
3. Replicar el ejercicio pero ahora cada una de las componentes tiene 500 observaciones. Comentar los resultados en base al criterio BIC y el gráfico de las curvas densidad estimadas.

Ejercicio 1 Old Faithful Geyser

En la base de datos *faithful* nos muestra 272 observaciones del tiempo de espera entre erupciones y duración de la erupción del géiser Old Faithful en el Parque Nacional Yellowstone, Wyoming, EE.UU.

1. Crear un histograma del tiempo de espera entre erupciones, ¿se aprecia algún patrón?
2. Ajustar un modelo de mixturas gamma para estos datos.
3. Transformar los datos restando uno menos su mínimo. Ajuste nuevamente la mixtura gamma. Comente sus resultados.

Mixtura con regresión Poisson

Sea Y_i la variable de respuesta para la observación i ($i = 1, 2, \dots, n$) y X_i el vector de covariables correspondiente. Supongamos que hay K componentes en la mezcla.

Entonces, la distribución de Y_i condicional a X_i y a la componente de la mezcla j ($j = 1, 2, \dots, K$) es una distribución Poisson con parámetro λ_{ij} , donde λ_{ij} se modela como:

$$\lambda_{ij} = \exp(\beta_{0j} + \beta_{1j}X_i)$$

para cada componente j , donde β_{0j} y β_{1j} son los parámetros de regresión correspondientes. Por lo tanto, la función de verosimilitud completa del modelo de mezcla de regresión Poisson es:

$$L(\Theta|\mathbf{y}, \mathbf{X}) = \prod_{i=1}^n \sum_{j=1}^K \pi_{ij} \frac{e^{-\lambda_{ij}} \lambda_{ij}^{y_i}}{y_i!}$$

Ejemplo 2

1. Generar una muestra aleatoria proveniente de una mixtura poisson con un regresor. Para esto asuma X es una muestra de uniformes entre 0 y 10. $\beta_{1,1} = 0,5$ y $\beta_{1,2} = 0,1$. Gráfique los puntos.
2. Utilizar la función *poisregmixEM()* para estimar los parámetros de la mixtura, compare la estimación para $k = 1, \dots, 4$.
3. Ajustar el modelo sin intercepto y compare sus resultados.
4. Calcular el BIC de cada uno de los modelos ajustados y seleccione el mejor bajo este criterio.

Ejercicio 2: Flujo de Bicicletas en los Puentes de la Ciudad de Nueva York Utilizaremos la base de datos de la Ayudantía N°5 la cual nos proporciona información acerca del flujo diario de bicicletas en los puentes que enlazan Manhattan con el resto de la metrópolis. Este conjunto de datos **Ay5_nyc-east-river-bicycle-counts.csv**. La base de datos nos proporciona información a lo largo de 210 días con las siguientes **variables a utilizar**:

- Manhattan.Bridge : Número de bicicletas que pasan por el puente de Manhattan.
- High.Temp...F.: Temperatura

1. Realizar un gráfico de dispersión entre la variable respuesta y las variables predictoras.
2. Ajustar un modelo de regresión Poisson con una sola componente.
3. Ajustar un modelo de regresión Poisson con dos componentes. Compare los resultados con el modelo anterior.
4. Analizar de los resultados, muestre el gráfico de los puntos con sus respectivo grupo.