

Laboratorio 6 - Medidas de Resumen

Daniel Saavedra y Mauricio Toro

Departamento de Estadística
Pontificia Universidad Católica de Chile

Martes 31 de Marzo, 2026



Contenidos

Introducción

Medidas de tendencia central

Medidas de dispersión

Medidas de posición

Actividad

Medidas de resumen univariadas

Se emplean para resumir y describir de manera concisa la información contenida en un conjunto de datos. Las principales medidas de resumen univariadas son:

- ▶ Medidas de tendencia central.
- ▶ Medidas de dispersión.
- ▶ Medidas de posición.

Cada una de estas medidas ofrece una mirada complementaria sobre distintos aspectos del comportamiento de una variable cuantitativa.

Base de datos: Iris

En el archivo Lab6.xlsx, hoja Iris, se encuentra información de diferentes características de 150 flores de 3 especies:

- ▶ Sepal.Length (Largo del sépalo, medido en cms.)
- ▶ Sepal.Width (Ancho del sépalo, medido en cms.)
- ▶ Petal.Length (Largo del pétalo, medido en cms.)
- ▶ Petal.Width (Ancho del pétalo, medido en cms.)
- ▶ Species (Especie)

Realice un análisis descriptivo de las variables numéricas, considerando medidas de posición, variabilidad, forma (asimetría y curtosis), además de las de tendencia central.

Realice el análisis del ancho del sépalo de las flores según especie. ¿Observa diferencias entre especies? Comente sus resultados.

Medidas de tendencia central

Proporcionan un valor que represente el *centro* o lo más típico de esos datos. Es decir, nos dan una idea de dónde se agrupan los valores. Las medidas de tendencia central son:

- ▶ Promedio.
- ▶ Mediana.
- ▶ Moda.

Todas estas medidas se pueden utilizar en variables cuantitativas (discretas o continuas). Sin embargo, veremos más adelante que la moda también se puede aplicar en variables cualitativas.

Promedio

Se refiere a la media aritmética, la suma de los números dividida por cuántos números se promedian:

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}.$$

Este valor es tal que la suma de las distancias desde las observaciones que están a su izquierda hasta ella es igual a la suma de las distancias desde las observaciones que están a su derecha hasta ella.

Ejemplo: Si un estudiante del curso tiene las siguientes calificaciones en el curso de análisis de datos: 7, 3, 4, 4 y 6, su promedio final será 4.8 y por lo tanto no necesitará rendir el examen.

En Excel lo podemos calcular mediante =PROMEDIO().

Mediana

Es el valor que se encuentra en el centro de un conjunto de datos ordenado de manera ascendente. Si el número de datos es impar, la mediana es el valor que se encuentra exactamente en el centro. En caso contrario, la mediana es el promedio de los dos valores centrales.

Ejemplo: Supongamos que tenemos las siguientes edades de un grupo de personas: 35, 40, 32, 25, 30. La mediana es 32. Esto significa que el 50% de las personas en este grupo tienen una edad inferior a 32 años, ó el 50% tiene una edad superior a 32 años.

En Excel la podemos calcular mediante =MEDIANA().

Sensibilidad del promedio y robustez de la mediana

Supongamos que nos encontramos registrando las edades de 4 estudiantes y accidentalmente nos equivocamos en uno de ellos, el promedio siempre será el más afectado a este tipo de observaciones atípicas a diferencia de la mediana (por cómo se encuentran definidos).

—	1	2	3	4	Promedio	Mediana
Falso	5	6	8	80	24.75	7
Verdadero	5	6	8	8	6.75	7

El promedio es considerado una medida de tendencia central sensible a los valores atípicos, mientras que la mediana es considerada una medida robusta a este tipo de observaciones.

Moda

Es el valor o los valores que aparecen con mayor frecuencia en un conjunto de datos. Un conjunto de datos puede tener una moda (unimodal), dos modas (bimodal), muchas (multimodal), o también puede no tener si todos los valores tienen la misma frecuencia.

Ejemplo: Supongamos que tienes los siguientes resultados de 10 lanzamientos de un dado: 2, 4, 6, 3, 2, 5, 2, 6, 4, 1. La moda en este caso es 2. Esto significa que, el número 2 ha sido lanzado más veces que cualquier otro número.

¡Cuidado! Esta medida no se utiliza en variables cuant. continuas.

En Excel la podemos calcular mediante `=MODA()` o `=MODA.VARIOS()`.

Medidas de dispersión

Nos permiten cuantificar la dispersión o el alejamiento de los datos respecto a un valor central, como la media. En la literatura, también se conocen como medidas de variabilidad. Las más utilizadas son:

- ▶ Rango.
- ▶ Rango intercuartílico.
- ▶ Varianza y desviación estándar.
- ▶ Coeficiente de dispersión.

Motivación

¿Qué tienen en común y en qué difieren las siguientes observaciones?

Grupo 1	-2	-1	0	1	2
Grupo 2	-10	-5	0	5	10
Grupo 3	-100	-50	0	50	100

Motivación

¿Qué tienen en común y en qué difieren las siguientes observaciones?

Grupo 1	-2	-1	0	1	2
Grupo 2	-10	-5	0	5	10
Grupo 3	-100	-50	0	50	100

Respuesta: Los tres conjuntos de datos coinciden en promedio y mediana (ambos son 0), sin embargo, difieren en la distancia que se alejan de ambos. Esto refleja que las medidas de tendencia central por sí mismas no son lo suficientemente informativas del comportamiento de un conjunto de datos.

Rango

Se define el rango de un conjunto de datos como la diferencia entre el valor máximo ($x_{\max}$) y el valor mínimo ($x_{\min}$):

$$\text{Rango} = x_{\max} - x_{\min},$$

Este valor proporciona una medida simple de la amplitud total de los datos, aunque no entrega información acerca de la distribución interna de los valores.

Ejemplo: Supongamos que tenemos las siguientes alturas de un grupo de personas: 160, 165, 170, 175, 180. El rango de este conjunto de datos es 20. Esto significa que hay una diferencia de 20 cm entre la persona más alta y la persona más baja en este grupo.

En Excel lo podemos calcular mediante `=MAX()-MIN()`.

Rango intercuartil

Se define como la diferencia entre el tercer cuartil $C3$ (el valor por debajo del cual se encuentra el 75% de los datos) y el primer cuartil $C1$ (el valor por debajo del cual se encuentra el 25% de los datos):

$$\text{Rango Intercuartil} = C3 - C1,$$

Este valor proporciona una medida de la amplitud del 50% de los datos más próximo a la mediana. Por lo tanto, proporciona una medida de dispersión que no se ve afectada por los valores atípicos en los extremos de la distribución de frecuencias.

En Excel lo podemos calcular mediante `=CUARTIL( ; 3) - CUARTIL( ; 1)`.

Varianza y desviación estándar

La varianza es el promedio de los cuadrados de las desviaciones de los valores individuales con respecto a la media:

$$s^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n - 1},$$

Sin embargo, esta no se puede interpretar en la misma escala que los datos originales. Es por ello que se suele utilizar su raíz, llamada desviación estándar:

$$s = \sqrt{s^2},$$

la cual cuantifica en cuánto difieren en promedio las observaciones con respecto a la media.

En Excel se utiliza =VAR.S() y =DESVEST.M(), respectivamente.

Coeficiente de variación

Se calcula dividiendo la desviación estándar de un conjunto de datos por el promedio y luego multiplicándolo por 100 para expresar el resultado en forma de porcentaje:

$$cv = \frac{s}{\bar{x}} \cdot 100\%,$$

Se utiliza para comparar la dispersión de diferentes conjuntos de datos que tienen diferentes unidades de medida o escalas.

Ejemplo: Si los cv de dos conjuntos de datos son 2.52% y 33.54%, respectivamente, significa que el segundo conjunto tiene una dispersión mayor al primero en comparación con sus promedios.

En Excel lo obtenemos como `=(DESVEST.M()/PROMEDIO())*100`.

Medidas de posición

Son estadísticas utilizadas para identificar y describir la ubicación relativa de un valor en comparación con otros valores dentro de un conjunto de datos. Las medidas de posición más comunes son:

- ▶ Cuartiles.
- ▶ Quintiles
- ▶ Deciles.
- ▶ Percentiles.

Estas medidas sólo pueden utilizar en variables cuantitativas.

Cuartiles

Los cuartiles son medidas estadísticas que dividen un conjunto de datos ordenados en cuatro partes iguales:

- ▶ El primer cuartil (C1) divide al conjunto de datos en el 25% inferior. El 25% de los datos es menor o igual a C1.
- ▶ El segundo cuartil (C2) divide al conjunto de datos en dos partes iguales. El 50% de los datos es menor o igual a C2.
- ▶ El tercer cuartil (C3) divide al conjunto de datos en el 75% inferior. El 75% de los datos es menor o igual a C3.

En Excel se pueden obtener como =CUARTIL(;1), =CUARTIL(;2) y =CUARTIL(;3), respectivamente.

Quintiles

Los quintiles son medidas estadísticas que dividen un conjunto de datos ordenados en cinco partes iguales:

- ▶ El primer quintil (Q1) divide el conjunto de datos en el 20% inferior. El 20% de los datos es menor o igual que Q1.
- ▶ El segundo quintil (Q2) divide el conjunto de datos en el 40% inferior. El 40% de los datos es menor o igual que Q2.
- ▶ El tercer quintil (Q3) divide el conjunto de datos en el 60% inferior. El 60% de los datos es menor o igual que Q3.
- ▶ El cuarto quintil (Q4) divide el conjunto de datos en el 80% inferior. El 80% de los datos es menor o igual que Q4.

En Excel se obtienen como =PERCENTIL(;0,2), =PERCENTIL(;0,4), =PERCENTIL(;0,6) y =PERCENTIL(;0,8), respectivamente.

Deciles

Los deciles son medidas estadísticas que dividen un conjunto de datos ordenados en diez partes iguales:

- ▶ El primer decil (D_1) divide el conjunto de datos en el 10% inferior. El 10% de los datos es menor o igual que D_1 .
- ▶ El segundo decil (D_2) divide el conjunto de datos en el 20% inferior. El 20% de los datos es menor o igual que D_2 .
- ▶ $\vdots$
- ▶ El noveno decil (D_9) divide el conjunto de datos en el 90% inferior. El 90% de los datos es menor o igual que D_9 .

En Excel se obtienen como `=PERCENTIL(;0,1)`, `=PERCENTIL(;0,2)`,
... y `=PERCENTIL(;0,9)`, respectivamente.

Percentiles

Los percentiles son medidas estadísticas que dividen un conjunto de datos ordenados en cien partes iguales:

- ▶ El primer percentil (P_1) divide el conjunto de datos en el 1% inferior. El 1% de los datos es menor o igual que P_1 .
- ▶ El segundo percentil (P_2) divide el conjunto de datos en el 2% inferior. El 2% de los datos es menor o igual que P_2 .
- ▶ $\vdots$

Observe las siguientes equivalencias:

$$\begin{aligned}C_1 &= P_{25}, C_2 = P_{50} \text{ y } C_3 = P_{75}. \\Q_1 &= P_{20}, Q_2 = P_{40}, Q_3 = P_{60} \text{ y } Q_4 = P_{80}. \\D_1 &= P_{10}, D_2 = P_{20}, \dots \text{ y } D_9 = P_{90}.\end{aligned}$$

En Excel se calculan como `=PERCENTIL(;a)`, donde $0 < a < 1$.

Actividad

Considere la base de datos `Lab6.xlsx`, hoja `cardio_train` disponible en CANVAS, en la cual se encuentran registros del estado médico de distintos pacientes. Para cada paciente se tiene la siguiente información:

- ▶ **id**: Identificador único del paciente.
- ▶ **age**: Edad del paciente (en días en la base original; puede convertirse a años dividiendo por 365).
- ▶ **gender**: Género del paciente (1: mujer, 2: hombre).
- ▶ **height**: Altura del paciente en centímetros.
- ▶ **weight**: Peso del paciente en kilogramos.
- ▶ **cholesterol**: Nivel de colesterol (1: normal, 2: sobre lo normal, 3: muy alto).
- ▶ **gluc**: Nivel de glucosa (1: normal, 2: sobre lo normal, 3: muy alto).
- ▶ **active**: Indicador de actividad física (0: inactivo, 1: activo).
- ▶ **cardio**: Presencia de enfermedad cardiovascular (0: no presenta, 1: presenta).

Actividad I

- ▶ Construya las tablas de distribución de frecuencias de todas las variables categóricas. Realice un gráfico adecuado que resuma la información. Para cada variable, indique cuál es la categoría modal.
- ▶ Describa numéricamente cómo es la distribución de la edad, el peso y la altura de los pacientes. Utilice medidas de tendencia central, dispersión, Apoye su análisis con gráficos adecuados.
- ▶ ¿Cuál es el la altura máxima del 35% de los pacientes más bajos? ¿Cómo cambia este valor al considerar el género de los pacientes?
- ▶ Entre el peso y la altura de las personas, ¿qué característica tiene mayor variabilidad? ¿Cambian los resultados si se hace el análisis según la condición de asma?