



FACULTAD DE MATEMÁTICAS
PONTIFICIA UNIVERSIDAD
CATÓLICA DE CHILE

EYP1113 - Probabilidad y Estadística

Capítulo 6: Inferencia Estadística

Ricardo Aravena C. - Cristian Capetillo C. - Ingrid Guevara R.
Bladimir Morales T. - Ricardo Olea O. - Daniel Saavedra M.

Facultad de Matemáticas
Departamento de Estadística
Pontificia Universidad Católica de Chile

Segundo Semestre 2024

Contenido I

Estimación

- Definiciones y Propiedades

Estimación Puntual

- Métodos de Estimación

Distribuciones Muestrales

- Distribución de la Media con Varianza Conocida

- Distribución de la Media con Varianza Desconocida

- Distribución de la Varianza Muestral

Prueba de Hipótesis

- Introducción

- Procedimiento para una Prueba de Hipótesis

- Ejemplos

- Potencia y β

Intervalos de Confianza

- Intervalo de Confianza para la media

- Determinación del Tamaño de Muestra

- Intervalo de Confianza para σ^2

Contenido II

Intervalos de Confianza Asintóticos

Comparación de dos Poblaciones

Estimación

Definiciones y Propiedades

En los capítulos previos hemos visto de manera introductoria como, dada una distribución ($p_X(x)$, $f_X(x)$ o $F_X(x)$) de una variable aleatoria X y el valor de sus parámetros, obtener probabilidades.

El calculo de probabilidades depende del valor de los parámetros.

Por tanto, nos interesa disponer de métodos que permitan seleccionar adecuadamente valores de estos para las distribuciones de importancia práctica.


Para realizar lo anteriormente expuesto, requerimos información “del mundo real”.

Por ejemplo, datos referente a la pluviosidad en cierta área, intensidad y frecuencia de los movimientos telúricos, conteos, velocidades y flujo de vehículos en cierta intersección o vía, etc.

Estimación

Definiciones y Propiedades

Con base a estos datos, los parámetros pueden ser estimados estadísticamente, y con información sobre el fenómeno inferir la distribución de probabilidad.




Introducción

Definiciones y Propiedades



Modelo probabilístico
Parámetros desconocidos



Estimación

Definiciones y Propiedades

La estimación clásica de parámetros consiste en dos tipos:

- ▶ **Puntal**: simplemente indica un valor único, basado en los datos, para representar el parámetro de interés.
- ▶ **Intervalar**: entrega un conjunto de valores (intervalo) donde el parámetro puede estar con cierto nivel de confianza.



Estimación

Definiciones y Propiedades

Propiedades deseables para un estimador puntual

- ▶ **Insesgamiento**: valor esperado del estimador sea igual al parámetro de interés.
- ▶ **Consistencia**: implica que si $n \rightarrow \infty$, el estimador converge al parámetro (propiedad asintótica)
- ▶ **Eficiencia**: se refiere a que la varianza del estimador. Dado un conjunto de datos, θ_1 es más eficiente que θ_2 para estimar θ si tiene menor varianza.
- ▶ **Suficiencia**: un estimador se dice suficiente si utiliza toda la información contenida en la muestra para estimar el parámetro.

Estimación

Ejemplo

Consideremos una población Normal(μ, σ) y queremos estimar el parámetro μ a partir de la información proveniente de una muestra aleatoria de tamaño n de esta población.

Se proponen los siguientes estimadores:

$$\hat{\mu}_1 = \frac{\max + \min}{2}, \quad \hat{\mu}_2 = \frac{Q_1 + Q_3}{2}, \quad \hat{\mu}_3 = Q_2, \quad \hat{\mu}_4 = \bar{X}_n$$

- ▶ Simule $n = 100, 500$ y 1000 observaciones proveniente de una población Normal($\mu = 10, \sigma = 1$).
- ▶ Guarde los estimadores propuestos.
- ▶ Repita los puntos anteriores m veces.
- ▶ Grafique los histogramas y diagramas de cajas.
- ▶ Compare sus medias y varianzas

Estimación Puntual

Métodos de Estimación

Método de los Momentos

En términos generales, el método propone igualar los momentos teóricos no centrales de una variable aleatoria X denotados por μ_k , con los momentos empíricos, basados en los datos, m_k , y despejar los parámetros de interés. Es decir,

$$\mu_k = E(X^k) \quad \text{y} \quad m_k = \frac{1}{n} \sum_{i=1}^n x_i^k$$

$$\Rightarrow \mu_k = m_k, \quad k = 1, 2, \dots$$



Estimación Puntual

Métodos de Estimación

Ejercicio Sean $X_1, \dots, X_n$ una muestra aleatoria cuya distribución de probabilidad está dada por:

- ▶ Bernoulli(p)
- ▶ Poisson(λ)
- ▶ Exponencial(ν)
- ▶ Gamma(k, ν)
- ▶ Normal(μ, σ)

Obtenga los estimadores de momentos de los parámetros.

Estimación Puntual

Métodos de Estimación

```
## Simulemos una Población ##  
set.seed(123456)  
Poblacion = rgamma(n = 1000000, rate = 0.4, shape = 8)  
hist(Poblacion, freq = F, col = "darkred",  
border = "white", nclass = 40, main = "", las = 1)  
  
## Obtengamos una Muestra ##  
n = 400  
Muestra = sample(Poblacion, size = n)  
hist(Muestra, freq = F, col = "darkred",  
border = "white", nclass = 10, main = "", las = 1)
```

Estimación Puntual

Métodos de Estimación

```
x = Muestra
```

```
## Gamma(k, nu) ##
```

```
nu = mean(x)/(mean(x^2)-mean(x)^2)
```

```
k = mean(x)^2/(mean(x^2)-mean(x)^2)
```

```
## Normal(mu, sigma) ##
```

```
x = Muestra
```

```
mu = mean(x)
```

```
sigma = sqrt(mean(x^2)-mean(x)^2)
```

```
## Log-Normal(lambda, zeta) ##
```

```
zeta = sqrt(log(mean(x^2))-2*log(mean(x)))
```

```
lambda = log(mean(x))-0.5*zeta^2
```

Estimación Puntual

Métodos de Estimación

```
hist(x, freq = F, col = "darkgray", border = "white",  
main = "", las = 1, ylim = c(0,0.07), nclass = 10)  
aux = seq(0,100,0.01)  
lines(aux, dgamma(aux, rate = 0.4, shape = 8),  
col = "black", lwd = 3)  
lines(aux, dgamma(aux, rate = nu, shape = k),  
col = "darkblue", lwd = 3)  
lines(aux, dnorm(aux, mean = mu, sd = sigma),  
col = "darkred", lwd = 3)  
lines(aux, dlnorm(aux, meanlog = lambda, sdlog = zeta),  
col = "darkgreen", lwd = 3)
```



Estimación Puntual


Métodos de Estimación

```
legend(x = 30, y = 0.07,  
col = c("black", "darkblue", "darkred", "darkgreen"), lwd = 3,  
c(expression("Gamma "(k==8,nu==0.4)),  
expression("Gamma "(hat(k), hat(nu))),  
expression(Normal(hat(mu), hat(sigma))),  
expression(Log-Normal(hat(lambda), hat(zeta))))  
, bty ="n", cex = 1.0)
```



Estimación Puntual

Métodos de Estimación



Estimación Puntual

Métodos de Estimación

Método de Máxima Verosimilitud

Otro método de estimación puntual es el denominado método de máxima verosimilitud (MV).

En contraste con el método de los momentos, el método de máxima verosimilitud deriva directamente en estimador puntual del parámetro de interés.

Sea X variable aleatoria con función de probabilidad $f_X(x, \theta)$, donde θ es el parámetro de interés.

Dada una muestra (es decir, valores observados) $x_1, \dots, x_n$, nos preguntamos cuál es el valor más probable de θ que produzca estos valores.

Estimación Puntual

Métodos de Estimación

Método de Máxima Verosimilitud

En otras palabras, para los diferentes valores de θ , cuál es el valor que maximiza la verosimilitud de los valores observados $x_1, \dots, x_n$.

La función de verosimilitud de una muestra aleatoria $x_1, \dots, x_n$, es decir, independiente e idénticamente distribuida es:

$$\begin{aligned} L(x_1, x_2, \dots, x_n, \theta) &= f_{X_1, \dots, X_n}(x_1, \dots, x_n, \theta) \\ &= f_{X_1}(x_1, \theta) \times \dots \times f_{X_n}(x_n, \theta), \quad \text{por independencia} \\ &= \prod_{i=1}^n f_X(x_i, \theta), \quad \text{por idéntica distribución} \end{aligned}$$

Se define el estimador de máxima verosimilitud (EMV) como el valor de θ que maximiza la función de verosimilitud L .

Estimación Puntual

Métodos de Estimación

Método de Máxima Verosimilitud

Es decir, es la solución de

$$\frac{\partial}{\partial \theta} L(x_1, x_2, \dots, x_n, \theta) = 0 \Rightarrow \hat{\theta} = \theta$$

Maximizar L es equivalente a maximizar $\ln L$, es decir,

$$\frac{\partial}{\partial \theta} \ln L(x_1, x_2, \dots, x_n, \theta) = 0$$

Estimación Puntual

Métodos de Estimación

Método de Máxima Verosimilitud

Si la función de distribución (discreta o continua) depende de más de un parámetro, digamos $\theta_1, \dots, \theta_m$, los EMV respectivos son las soluciones de las m ecuaciones:

$$\frac{\partial}{\partial \theta_j} \ln L(x_1, x_2, \dots, x_n, \theta_1, \dots, \theta_m) = 0 \quad j = 1, 2, \dots, m$$

Los EMV son estimadores que poseen las propiedades deseables descritas anteriormente.

En particular, para n grande, son “los mejores” estimadores (en el sentido de varianza mínima)

Estimación Puntual

Métodos de Estimación

Ejercicio

Sean $X_1, \dots, X_n$ una muestra aleatoria cuya distribución de probabilidad está dada por:

- ▶ Bernoulli(p)
- ▶ Poisson(λ)
- ▶ Exponencial(ν)
- ▶ Gamma(k, ν)
- ▶ Normal(μ, σ)

Obtenga los estimadores máximo verosímiles de los parámetros.

Estimación Puntual


Métodos de Estimación

```
n = 200
nu = 0.4
x = rexp(n, rate = nu)
nu = seq(0,0.8,0.001)
Lik = nu^(n) * exp(-nu*sum(x))
plot(Lik ~ nu, col = "darkred", bty = "n",
type = "l", yaxt = "n", xlab = expression(nu),
ylab = "", cex.lab = 1.5)
```



Estimación Puntual

Métodos de Estimación



Estimación Puntual

Métodos de Estimación

Propiedades de los Estimadores Máximo Verosímiles

- ▶ Asintóticamente Insesgados: $E(\hat{\theta}_n) \rightarrow \theta$, cuando $n \rightarrow \infty$.
- ▶ Varianza alcanza la cota de Cramer-Rao:

$$\text{Var}(\hat{\theta}_n) = \frac{1}{I_n(\theta)},$$

$$\text{con } I_n(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \ln L(\theta) \right].$$

- ▶ Distribución Asintótica: Normal.
- ▶ Invarianza: Si $\hat{\theta}_n$ es el estimador máximo verosímil de θ , entonces $g(\hat{\theta}_n)$ es el estimador máximo verosímil de $g(\theta)$ cuya distribución asintótica es

$$g(\hat{\theta}) \sim \text{Normal} \left(g(\theta), \sqrt{\frac{[g'(\theta)]^2}{I_n(\theta)}} \right)$$

Distribuciones Muestrales

Distribución de la Media con Varianza Conocida

Sea $X_1, \dots, X_n$ una sucesión de variables aleatorias independientes con función de probabilidad $p_X(x)$ o de densidad $f_X(x)$.

Si $E(X) = \mu$ y $\text{Var}(X) = \sigma^2$, entonces el valor esperado y varianza de $\bar{X}_n$ son

$$\begin{aligned}\mu_{\bar{X}_n} &= E(\bar{X}_n) = \mu \\ \sigma_{\bar{X}_n}^2 &= \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}\end{aligned}$$



Distribuciones Muestrales

Distribución de la Media con Varianza Conocida

Si la distribución subyacente es Normal, entonces

$$\bar{X}_n \sim \text{Normal} \left(\mu, \frac{\sigma}{\sqrt{n}} \right)$$

En el caso que la distribución NO sea Normal, por el Teorema del Límite Central para n grande se cumple que

$$\bar{X}_n \stackrel{\text{aprox}}{\sim} \text{Normal} \left(\mu, \frac{\sigma}{\sqrt{n}} \right) \Rightarrow \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \stackrel{\text{aprox}}{\sim} \text{Normal}(0, 1)$$



Distribuciones Muestrales

Distribución de la Media con Varianza Desconocida

Sea $X_1, \dots, X_n$ una sucesión de variables aleatorias independientes con función de probabilidad $p_X(x)$ o de densidad $f_X(x)$ tal que $E(X) = \mu$ y $\text{Var}(X) = \sigma^2$.

Generalmente la varianza poblacional es desconocida.

Bajo Normalidad, si reemplazamos σ^2 por su estimador muestral S^2 se tiene que

$$\frac{\bar{X}_n - \mu}{S/\sqrt{n}} \sim \text{t-student}(n-1)$$

con

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Distribuciones Muestrales

Distribución de la Varianza Muestral

Notemos que bajo Normalidad

$$\frac{(n-1) \cdot S^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2 \sim \text{Gamma} \left(\frac{n-1}{2}, \frac{1}{2\sigma^2} \right) = \chi^2(n-1)$$

y por lo tanto

$$S^2 \sim \text{Gamma} \left(\frac{n-1}{2}, \frac{(n-1)}{2\sigma^2} \right),$$

lo que implica que $E(S^2) = \sigma^2$.

Prueba de Hipótesis

Introducción

Una prueba de hipótesis es un método estadístico inferencial para la toma de decisiones sobre una población en base a la información proporcionada por los datos de una muestra.

La inferencia puede hacerse con respecto a uno o más parámetros de la población o también para un modelo de distribución.



Prueba de Hipótesis

Introducción

Prueba de Hipótesis Una hipótesis es una afirmación con respecto a uno o más parámetros de una población.

Usualmente son dos las hipótesis que se contrastan son:

- ▶ Hipótesis nula, H_0 .
- ▶ Hipótesis alternativa, H_a .

Ejemplo: Cuando interesa inferir sobre el valor de un parámetro μ de la población las hipótesis a contrastar son generalmente:

$$H_0 : \mu = \mu_0 \quad \text{vs} \quad H_a : \mu \neq \mu_0$$

Prueba de Hipótesis

Procedimiento para una Prueba de Hipótesis

Los pasos necesarios en las pruebas de hipótesis son:

1. Defina la hipótesis nula y alternativa.

$$H_0 : \mu = \mu_0 \quad \text{vs} \quad H_a : \mu \neq \mu_0$$

$$H_0 : \mu = \mu_0 \quad \text{vs} \quad H_a : \mu > \mu_0$$

$$H_0 : \mu = \mu_0 \quad \text{vs} \quad H_a : \mu < \mu_0$$

2. Identificar la prueba estadística adecuada y su distribución.
3. Basado en una muestra de datos observados estime el estadístico de prueba.
4. Especifique el nivel de significancia.

Prueba de Hipótesis

Procedimiento para una Prueba de Hipótesis

Dado que el estadístico de prueba es una variable aleatoria, la probabilidad de una decisión errónea puede ser controlada. Los errores que se pueden cometer son:

- ▶ **Error Tipo I:** Se rechaza H_0 dado que era correcta.
- ▶ **Error Tipo II:** No se rechaza H_0 dado que no era correcta.

La probabilidad de **Error Tipo I** se denota como α , la cual corresponde al nivel de significancia de la prueba de hipótesis.

La probabilidad real de cometer **Error Tipo I** se conoce como valor- p .

Prueba de Hipótesis

Procedimiento para una Prueba de Hipótesis



Prueba de Hipótesis

Ejemplos


Sea $X_1, \dots, X_n$ una muestra aleatoria proveniente de una distribución Normal(μ, σ), determine una prueba de hipótesis para:

- ▶ μ , con σ^2 conocido.
- ▶ μ , con σ^2 desconocido.
- ▶ σ^2 .

Prueba de Hipótesis

Prueba de hipótesis para μ , con σ^2 conocido


Si H_0 es correcta, entonces $Z_0 = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \text{Normal}(0, 1)$



Prueba de Hipótesis

Prueba de hipótesis para μ , con σ^2 conocido


i. ($H_0 : \mu = \mu_0$) vs ($H_a : \mu \neq \mu_0$)



Prueba de Hipótesis

Prueba de hipótesis para μ , con σ^2 conocido


ii. ($H_0 : \mu = \mu_0$) vs ($H_a : \mu > \mu_0$)



Prueba de Hipótesis

Prueba de hipótesis para μ , con σ^2 conocido


iii. ($H_0 : \mu = \mu_0$) vs ($H_a : \mu < \mu_0$)



Prueba de Hipótesis

Prueba de hipótesis para μ , con σ^2 desconocido


Si H_0 es correcta, entonces $T_0 = \frac{\bar{X} - \mu_0}{s/\sqrt{n}} \sim t\text{-Student}(n-1)$



Prueba de Hipótesis

Prueba de hipótesis para μ , con σ^2 desconocido


i. ($H_0 : \mu = \mu_0$) vs ($H_a : \mu \neq \mu_0$)



Prueba de Hipótesis

Prueba de hipótesis para μ , con σ^2 desconocido


ii. ($H_0 : \mu = \mu_0$) vs ($H_a : \mu > \mu_0$)



Prueba de Hipótesis

Prueba de hipótesis para μ , con σ^2 desconocido


iii. ($H_0 : \mu = \mu_0$) vs ($H_a : \mu < \mu_0$)



Prueba de Hipótesis

Prueba de hipótesis σ^2 , con μ desconocido


Si H_0 es correcta, entonces $C_0 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$



Prueba de Hipótesis

Prueba de hipótesis σ^2 , con μ desconocido


i. ($H_0 : \sigma = \sigma_0$) vs ($H_a : \sigma \neq \sigma_0$)



Prueba de Hipótesis

Prueba de hipótesis σ^2 , con μ desconocido


ii. ($H_0 : \sigma = \sigma_0$) vs ($H_a : \sigma > \sigma_0$)



Prueba de Hipótesis

Prueba de hipótesis σ^2 , con μ desconocido

iii. ($H_0 : \sigma = \sigma_0$) vs ($H_a : \sigma < \sigma_0$)



Prueba de Hipótesis

Ejemplos

Sea $X_1, \dots, X_n$ una muestra aleatoria proveniente de una distribución cuya función densidad f_θ depende de un parámetro θ y $\hat{\theta}$ es el estimador de máxima verosimilitud, entonces para las hipótesis

$$H_0 : \theta = \theta_0 \quad \text{vs} \quad H_a : \theta \neq \theta_0$$

$$H_0 : \theta = \theta_0 \quad \text{vs} \quad H_a : \theta > \theta_0$$

$$H_0 : \theta = \theta_0 \quad \text{vs} \quad H_a : \theta < \theta_0$$

Un estadístico de prueba aproximado sería

$$Z_0 = \sqrt{I_n(\theta_0)}(\hat{\theta} - \theta_0) \overset{\text{aprox}}{\sim} \text{Normal}(0, 1)$$

Construya los estadísticos de pruebas para los siguientes casos:

- ▶ Bernoulli(p)
- ▶ Poisson(λ)
- ▶ Exponencial(ν)

Prueba de Hipótesis

Potencia y β

Se denota como β a la probabilidad de cometer un error de tipo II en una prueba de hipótesis, teniendo en cuenta el nivel de significancia α . Mientras que su complemento se conoce como la potencia de un test, es decir:

$$\beta = P(\text{No rechazar } H_0 \mid H_0 \text{ es falsa})$$

$$\text{Potencia} = P(\text{Rechazar } H_0 \mid H_0 \text{ es falsa})$$



Prueba de Hipótesis

Potencia y β

Por ejemplo, considere $X_1, \dots, X_n$ una muestra aleatoria proveniente de una distribución $\text{Normal}(\mu, \sigma)$. Tenemos que $\bar{X}_n$ es un estimador insesgado y consistente para el parámetro μ , con distribución $\text{Normal}(\mu, \sigma/\sqrt{n})$.

Si queremos contrastar las siguientes hipótesis:

$$H_0 : \mu = \mu_0 \quad \text{vs} \quad H_a : \mu \neq \mu_0 \quad (1)$$

$$H_0 : \mu \leq \mu_0 \quad \text{vs} \quad H_a : \mu > \mu_0 \quad (2)$$

$$H_0 : \mu \geq \mu_0 \quad \text{vs} \quad H_a : \mu < \mu_0 \quad (3)$$

El estadístico de prueba, bajo el supuesto que H_0 es correcta (se considera siempre como referencia $H_0 : \mu = \mu_0$) y σ conocido

$$Z_0 = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}} \sim \text{Normal}(0, 1)$$

Prueba de Hipótesis

Potencia y β

Para (1) se rechaza H_0 si $|Z_0| > k_{1-\alpha/2}$, entonces

$$\text{Potencia} = 1 - \beta$$

$$= 1 - P(\text{Error Tipo II})$$

$$= 1 - P(\text{No rechazar } H_0 \mid H_0 \text{ es falsa})$$

$$= P(\text{Rechazar } H_0 \mid H_0 \text{ es falsa})$$

$$= P(|Z_0| > k_{1-\alpha/2} \mid \mu = \mu_0 + \Delta)$$

$$= P\left(\left|\frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}}\right| > k_{1-\alpha/2} \mid \mu = \mu_0 + \Delta\right)$$

$$= P\left(\frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}} > k_{1-\alpha/2} \mid \mu = \mu_0 + \Delta\right) + P\left(\frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}} < -k_{1-\alpha/2} \mid \mu = \mu_0 + \Delta\right)$$

$$= P\left(\frac{\bar{X}_n - (\mu_0 + \Delta)}{\sigma/\sqrt{n}} > k_{1-\alpha/2} - \Delta \frac{\sqrt{n}}{\sigma} \mid \mu = \mu_0 + \Delta\right) + P\left(\frac{\bar{X}_n - (\mu_0 + \Delta)}{\sigma/\sqrt{n}} < -k_{1-\alpha/2} - \Delta \frac{\sqrt{n}}{\sigma} \mid \mu = \mu_0 + \Delta\right)$$



$$= P\left(\frac{\bar{X}_n - (\mu_0 + \Delta)}{\sigma/\sqrt{n}} > k_{1-\alpha/2} - \Delta \frac{\sqrt{n}}{\sigma} \mid \mu = \mu_0 + \Delta\right) + P\left(\frac{\bar{X}_n - (\mu_0 + \Delta)}{\sigma/\sqrt{n}} < k_{\alpha/2} - \Delta \frac{\sqrt{n}}{\sigma} \mid \mu = \mu_0 + \Delta\right)$$

$$= 1 - \Phi\left(k_{1-\alpha/2} - \Delta \frac{\sqrt{n}}{\sigma}\right) + \Phi\left(k_{\alpha/2} - \Delta \frac{\sqrt{n}}{\sigma}\right)$$

Prueba de Hipótesis

Potencia

Notar que para $\Delta = 0 \rightarrow \mu = \mu_0$ y la Potencia es igual a α



Prueba de Hipótesis

Potencia y β



Para (2) se rechaza H_0 si $Z_0 > k_{1-\alpha}$, entonces

$$\begin{aligned}\text{Potencia} &= 1 - \beta \\&= 1 - P(\text{Error Tipo II}) \\&= 1 - P(\text{No rechazar } H_0 \mid H_0 \text{ es falsa}) \\&= P(\text{Rechazar } H_0 \mid H_0 \text{ es falsa}) \\&= P(Z_0 > k_{1-\alpha} \mid \mu = \mu_0 + \Delta) \\&= P\left(\frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}} > k_{1-\alpha} \mid \mu = \mu_0 + \Delta\right) \\&= P\left(\frac{\bar{X}_n - (\mu_0 + \Delta)}{\sigma/\sqrt{n}} > k_{1-\alpha} - \Delta \frac{\sqrt{n}}{\sigma} \mid \mu = \mu_0 + \Delta\right) \\&= 1 - \Phi\left(k_{1-\alpha} - \Delta \frac{\sqrt{n}}{\sigma}\right)\end{aligned}$$

Prueba de Hipótesis

Potencia y β

Notar que para $\Delta = 0 \rightarrow \mu = \mu_0$ y la Potencia es igual a α



Prueba de Hipótesis

Potencia y β



Para (3) se rechaza H_0 si $Z_0 < k_\alpha$, entonces

$$\begin{aligned}\text{Potencia} &= 1 - \beta \\&= 1 - P(\text{Error Tipo II}) \\&= 1 - P(\text{No rechazar } H_0 \mid H_0 \text{ es falsa}) \\&= P(\text{Rechazar } H_0 \mid H_0 \text{ es falsa}) \\&= P(Z_0 < k_\alpha \mid \mu = \mu_0 + \Delta) \\&= P\left(\frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}} < k_\alpha \mid \mu = \mu_0 + \Delta\right) \\&= P\left(\frac{\bar{X}_n - (\mu_0 + \Delta)}{\sigma/\sqrt{n}} < k_\alpha - \Delta \frac{\sqrt{n}}{\sigma} \mid \mu = \mu_0 + \Delta\right) \\&= \Phi\left(k_\alpha - \Delta \frac{\sqrt{n}}{\sigma}\right)\end{aligned}$$

Prueba de Hipótesis

Potencia y β

Notar que para $\Delta = 0 \rightarrow \mu = \mu_0$ y la Potencia es igual a α



Intervalos de Confianza

Intervalo de Confianza para la media

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población cuya distribución es $\text{Normal}(\mu, \sigma)$.

Ya vimos que un estimador insesgado y consistente para μ esta dado por

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \sim \text{Normal} \left(\mu, \frac{\sigma}{\sqrt{n}} \right)$$

Intervalos de Confianza

Intervalo de Confianza para la media

Intervalo de Confianza para μ con σ conocido

Tenemos que

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim \text{Normal}(0, 1)$$

Luego, se puede mostrar que

$$P(\mu \in \bar{X}_n \pm k_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}) = 1 - \alpha$$

Intervalos de Confianza

Intervalo de Confianza para la media

Intervalo de Confianza para μ con σ desconocido

Tenemos que

$$T_n = \frac{\bar{X}_n - \mu}{S/\sqrt{n}} \sim \text{t-student}(n-1)$$

Luego, se puede mostrar que

$$P(\mu \in \bar{X}_n \pm t_{1-\alpha/2}(n-1) \cdot \frac{S}{\sqrt{n}}) = 1-\alpha$$

Intervalos de Confianza

Determinación del Tamaño de Muestra

Como se aprecia en la construcción de los Intervalos de Confianza, el tamaño de muestra es fundamental.

Al observar el Intervalo de Confianza para μ , se aprecia que el semi-ancho esta dado por:

$$k_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} = w$$

Lo anterior se conoce como **Error de Estimación**.

Intervalos de Confianza

Determinación del Tamaño de Muestra

Por lo tanto, para una precisión w dada, es posible determinar el tamaño de muestra necesaria, con σ y α fijos, dado por

$$n = \left(\frac{k_{1-\alpha/2} \sigma}{w} \right)^2$$

Nota: Alternativamente también se puede determinar un tamaño muestral a partir controlando por los errores tipo I y II de una prueba de hipótesis.



Intervalos de Confianza

Intervalo de Confianza para σ^2

Consideremos nuevamente una muestra aleatoria $X_1, \dots, X_n$ proveniente de una población cuya distribución es $\text{Normal}(\mu, \sigma)$.

Recordemos que un estimador insesgado y consistente para σ^2 está dado por:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \Rightarrow \frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{(n-1)}$$

Intervalos de Confianza

Intervalo de Confianza para σ^2

Tenemos que

$$C_n = \frac{(n-1) S^2}{\sigma^2} \sim \chi^2_{(n-1)}$$

Luego, se puede mostrar que

$$< \sigma^2 >_{1-\alpha} \in \left[\frac{(n-1) S^2}{c_{1-\alpha/2}(n-1)}; \frac{(n-1) S^2}{c_{\alpha/2}(n-1)} \right]$$

Intervalos de Confianza

Intervalo de Confianza Asintóticos

Sea $\hat{\theta}$ el estimados de máxima verosimilitud de un parámetro θ .

A partir del siguiente pivote

$$Z_n = \frac{\hat{\theta} - \theta}{\sqrt{\widehat{\text{Var}}(\hat{\theta})}} \underset{\text{aprox}}{\sim} \text{Normal}(0, 1)$$

se tiene que

$$P(\theta \in \hat{\theta} \pm k_{1-\alpha/2} \cdot \sqrt{\widehat{\text{Var}}(\hat{\theta})}) = 1 - \alpha$$

Intervalos de Confianza

Intervalo de Confianza Asintóticos: Proporción

Por ejemplo, consideremos una muestra aleatoria $X_1, \dots, X_n$ proveniente de una población cuya distribución es Bernoulli(p).

Ya vimos que un estimador insesgado y consistente para p esta dado por:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \stackrel{\text{aprox.}}{\sim} \text{Normal} \left(p, \sqrt{\frac{p(1-p)}{n}} \right)$$

Intervalos de Confianza

Intervalo de Confianza Asintóticos: Proporción

Tenemos que

$$Z_n = \frac{\bar{X}_n - p}{\sqrt{\frac{\bar{X}_n(1-\bar{X}_n)}{n}}} \stackrel{\text{aprox.}}{\sim} \text{Normal}(0, 1),$$

Luego,

$$p_{1-\alpha} \in \bar{X}_n \pm k_{1-\alpha/2} \cdot \sqrt{\frac{\bar{X}_n(1-\bar{X}_n)}{n}}$$

Comparación de dos Poblaciones

Sean $X_1, \dots, X_n$ e $Y_1, \dots, Y_m$ dos muestras aleatorias independientes con distribución $\text{Normal}(\mu_X, \sigma_X)$ y $\text{Normal}(\mu_Y, \sigma_Y)$ respectivamente.

Con medias y varianzas muestrales dadas por:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \quad \bar{Y}_m = \frac{1}{m} \sum_{j=1}^m Y_j$$

$$S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \quad S_Y^2 = \frac{1}{m-1} \sum_{j=1}^m (Y_j - \bar{Y}_m)^2$$

Comparación de dos Poblaciones

Entonces

- ▶ Si σ_X y σ_Y son conocidos:

$$\frac{(\bar{X}_n - \bar{Y}_m) - (\mu_X - \mu_Y)}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} \sim \text{Normal}(0, 1)$$

- ▶ Si σ_X y σ_Y son desconocidos pero iguales:

$$\frac{(\bar{X}_n - \bar{Y}_m) - (\mu_X - \mu_Y)}{S_p \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim t - \text{Student}(n + m - 2)$$

$$\text{con } S_p^2 = \frac{(n-1) S_X^2 + (m-1) S_Y^2}{n + m - 2}$$

Comparación de dos Poblaciones

Entonces

- Si σ_X y σ_Y son desconocidos:

$$\frac{(\bar{X}_n - \bar{Y}_m) - (\mu_X - \mu_Y)}{\sqrt{\frac{S_X^2}{n} + \frac{S_Y^2}{m}}} \sim t - \text{Student}(\nu)$$

con

$$\nu = \left[\frac{(S_X^2/n + S_Y^2/m)^2}{\frac{(S_X^2/n)^2}{n-1} + \frac{(S_Y^2/m)^2}{m-1}} \right]$$

- Si μ_X y μ_Y son desconocidos:

$$\frac{[(n-1) S_X^2 / \sigma_X^2] / (n-1)}{[(m-1) S_Y^2 / \sigma_Y^2] / (m-1)} = \frac{S_X^2}{S_Y^2} \cdot \frac{\sigma_Y^2}{\sigma_X^2} \sim F(n-1, m-1)$$

Comparación de dos Poblaciones

Sean $X_1, \dots, X_n$ e $Y_1, \dots, Y_m$ dos muestras aleatorias independientes con distribución Bernoulli(p_X) y Bernoulli(p_Y) respectivamente, entonces

$$\frac{(\bar{X}_n - \bar{Y}_m) - (p_X - p_Y)}{\sqrt{\frac{p_X(1-p_X)}{n} + \frac{p_Y(1-p_Y)}{m}}} \stackrel{\text{aprox}}{\sim} \text{Normal}(0, 1)$$

y

$$\frac{(\bar{X}_n - \bar{Y}_m) - (p_X - p_Y)}{\sqrt{\frac{\bar{X}_n(1-\bar{X}_n)}{n} + \frac{\bar{Y}_m(1-\bar{Y}_m)}{m}}} \stackrel{\text{aprox}}{\sim} \text{Normal}(0, 1)$$

Comparación de dos Poblaciones

Sean $X_1, \dots, X_n$ e $Y_1, \dots, Y_m$ dos muestras aleatorias independientes con distribución $\text{Poisson}(\lambda_X)$ y $\text{Poisson}(\lambda_Y)$ respectivamente, entonces

$$\frac{(\bar{X}_n - \bar{Y}_m) - (\lambda_X - \lambda_Y)}{\sqrt{\frac{\lambda_X}{n} + \frac{\lambda_Y}{m}}} \underset{\text{aprox}}{\sim} \text{Normal}(0, 1)$$

y

$$\frac{(\bar{X}_n - \bar{Y}_m) - (\lambda_X - \lambda_Y)}{\sqrt{\frac{\bar{X}_n}{n} + \frac{\bar{Y}_m}{m}}} \underset{\text{aprox}}{\sim} \text{Normal}(0, 1)$$

Comparación de dos Poblaciones

Sean $X_1, \dots, X_n$ e $Y_1, \dots, Y_m$ dos muestras aleatorias independientes con distribución Exponencial(ν_X) y Exponencial(ν_Y) respectivamente, entonces

$$\frac{(\bar{X}_n - \bar{Y}_m) - \left(\frac{1}{\nu_X} - \frac{1}{\nu_Y}\right)}{\sqrt{\frac{1}{n\nu_X^2} + \frac{1}{m\nu_Y^2}}} \underset{\text{aprox}}{\sim} \text{Normal}(0, 1)$$

y

$$\frac{(\bar{X}_n - \bar{Y}_m) - \left(\frac{1}{\nu_X} - \frac{1}{\nu_Y}\right)}{\sqrt{\frac{\bar{X}_n^2}{n} + \frac{\bar{Y}_m^2}{m}}} \underset{\text{aprox}}{\sim} \text{Normal}(0, 1)$$