



FACULTAD DE MATEMÁTICAS
PONTIFICIA UNIVERSIDAD
CATÓLICA DE CHILE

EYP1113 - Probabilidad y Estadística

Capítulo 3: Modelos analíticos de fenómenos aleatorios

Ricardo Aravena C. - Cristian Capetillo C. - Ingrid Guevara R.
Bladimir Morales T. - Ricardo Olea O. - Daniel Saavedra M.

Facultad de Matemáticas
Departamento de Estadística
Pontificia Universidad Católica de Chile

Segundo Semestre 2024

Contenido I

Variables Aleatorias y Distribución de Probabilidad

- Eventos Aleatorios y Variables Aleatorias

- Distribución de Probabilidades de una Variable Aleatoria

- Medidas Descriptivas de Variables Aleatorias

Distribuciones de Probabilidad

- Distribución Normal

- Distribución Log-Normal

- Distribución Binomial y Bernoulli

- Distribución Geométrica

- Distribución Binomial Negativa

- Distribución de Poisson

- Distribución Exponencial

- Distribución Gamma

- Distribución Hipergeométrica

- Distribución Beta

Otras Distribuciones de Probabilidad

- Distribución Weibull

- Distribución Logística

- Distribución Log-Logística

- Distribución t-Student

- Distribución Fisher

Contenido II

Múltiples Variables Aleatorias

Distribución de Probabilidad Conjunta y Condicional

Distribuciones Marginales y Condicionales

Covarianza y Correlación

Esperanza Condicional y Predicción

Definiciones y Ejemplos

Predicción

Variables Aleatorias y Distribución de Probabilidad

Ya vimos los conceptos fundamentales y las herramientas referidas a la ocurrencia de fenómenos aleatorios y la determinación de las probabilidades asociadas.

Ahora, introduciremos modelos analíticos que involucran:

Variables Aleatorias y Distribución de Probabilidad



Variables Aleatorias y Distribución de Probabilidad

Eventos Aleatorios y Variables Aleatorias

Una variable aleatoria es el vehículo matemático para representar un evento en términos analíticos.

El valor de una variable aleatoria puede estar definida para un conjunto de posibles valores.

Si X es una variable aleatoria, entonces

$$X = x, \quad X < x, \quad X > x, \quad a < X \leq X$$


representan distintos eventos.

Notemos que la asignación numérica puede ser natural o artificial.

Variables Aleatorias y Distribución de Probabilidad

Eventos Aleatorios y Variables Aleatorias

Formalmente, una variable aleatoria puede ser considerada como una función o regla sobre los eventos del espacio muestral a un sistema numérico (o línea real).



Variables Aleatorias y Distribución de Probabilidad

Eventos Aleatorios y Variables Aleatorias

Así, los eventos E_1 y E_2 pueden corresponder a

$$E_1 = (a < X \leq b)$$

$$E_2 = (c < X \leq d)$$

$$\overline{E_1 \cup E_2} = (X \leq a) \cup (X > d)$$

$$E_1 \cap E_2 = (c < X \leq b)$$

Una variable aleatoria puede ser discreta o continua.

Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria

Para los valores o rango de valores que puede tomar una variable aleatoria tienen asociados una probabilidad específica o medidas de probabilidad.

La regla que asigna las medidas de probabilidad se denomina:

“Distribución ó Ley de probabilidad”



Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria

Si X es variable aleatoria, la distribución de probabilidad puede ser descrita por su función de distribución de probabilidad acumulada denotada por:

$$F_X(x) = P(X \leq x) \quad \text{para todo } x \in \mathbb{R}$$

Si X es variable aleatoria discreta, entonces esta función puede ser expresada a través de la función de probabilidad “puntual” denotada por

$$p_X(x) = P(X = x)$$

Así,

$$F_X(x) = \sum_{x_i \leq x} P(X = x_i) = \sum_{x_i \leq x} p_X(x_i),$$

con $x_i \in \Theta_X$ (soporte de X).

Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria

Ahora, si X es variable aleatoria continua, las probabilidades están asociadas a intervalos de x .

En este caso se define la función de densidad $f_X(x)$ tal que

$$P(a < X \leq b) = \int_a^b f_X(x) dx \quad (1)$$

y

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(t) dt$$

con

$$f_X(x) = \frac{d}{dx} F_X(x)$$





Notar que

$$P(x < X \leq x + dx) = f_X(x) dx$$

Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria



Caso Discreto y Continuo



Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria

Caso Mixto



Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria

Propiedades

1. $F_X(-\infty) = 0$ y $F_X(\infty) = 1$.
2. $F_X(x) \geq 0$ para todo valor de x y es no decreciente.
3. $F_X(x)$ es continua por la derecha

Para el caso continuo, la ecuación (1) la podemos escribir como

$$P(a < X \leq b) = \int_{-\infty}^b f_X(x) dx - \int_{-\infty}^a f_X(x) dx$$

mientras que en el caso discreto

$$P(a < X \leq b) = \sum_{x_i \leq b} p_X(x_i) - \sum_{x_i \leq a} p_X(x_i)$$


es decir, para ambos casos

$$P(a < X \leq b) = F_X(b) - F_X(a)$$

Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria


Aplicación: Sismos ocurridos en Chile entre los años 2003 y 2005.



Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria

Ejemplo 3.1 Definamos como X al tiempo entre sismos ocurridos en nuestro país.



Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria

Este comportamiento puede ser descrito con una distribución cuya función de densidad es de la siguiente forma:


$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & \text{en otro caso} \end{cases}$$

en que λ es una constante positiva. Esta distribución se conoce como distribución **Exponencial**.

Las funciones **dexp()** y **pexp()** de R, evalúan la función de densidad y de probabilidad acumulada para un valor en los reales.

Variables Aleatorias y Distribución de Probabilidad


Distribución de Probabilidades de una Variable Aleatoria



Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria

Ejemplo 3.2 Definamos como Y al número de sismos diarios ocurridos en nuestro país.



Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria

Este comportamiento puede ser descrito con una distribución cuya función de probabilidad es de la siguiente forma:


$$p_Y(y) = \begin{cases} \frac{\lambda^y e^{-\lambda}}{y!}, & y \in \mathbb{N}_0 \\ 0, & \text{en otro caso} \end{cases}$$

en que λ es una constante positiva. Esta distribución se conoce como distribución **Poisson**.

Las funciones **dpois()** y **ppois()** de R, evalúan la función de probabilidad y de probabilidad acumulada para un valor en los reales.

Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria



Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria


Ejemplo 3.3 Los números aleatorios son la base esencial de la simulación de variables aleatorias que veremos más adelante. Como primera experiencia supongamos que cada alumno de la universidad va a elegir totalmente al azar un número entre 2 y 5.

```
set.seed(1113) ## Semilla de simulación
U = runif(20000, 2, 5)
hist(U, freq = FALSE, col = "gray", border = "white",
las = 1, nclass = 5, main = "", xlab = expression(Theta[U]))
```



Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria



Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria

Una función densidad constante en el intervalo $[2, 5]$ y cero en otro caso, ajusta de buena manera el comportamiento de los datos:


$$f_X(x) = \begin{cases} c, & 2 \leq x \leq 5 \\ 0, & \text{en otro caso} \end{cases}$$

Notar que la constante c para este caso es igual a $\frac{1}{5-2}$.



Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria



Variables Aleatorias y Distribución de Probabilidad

Distribución de Probabilidades de una Variable Aleatoria

A este modelo se le conoce como $\text{Uniforme}(a, b)$, donde

$$f(u) = \frac{1}{b-a} \quad \text{y} \quad F(u) = \frac{u-a}{b-a}$$

para $u \in [a, b]$

Variables Aleatorias y Distribución de Probabilidad

Medidas Descriptivas de Variables Aleatorias

Una variable aleatoria puede ser descrita totalmente por su **función de distribución de probabilidad o de densidad**, o bien por su **función de distribución de probabilidad acumulada**.

Sin embargo, en la práctica la forma exacta puede no ser totalmente conocida.

En tales casos se requieren ciertas “medidas” para tener una idea de la forma de la distribución:

- ▶ Medidas Centrales.
- ▶ Medidas de Posición.
- ▶ Medidas de Dispersión.
- ▶ Medidas de Asimetrías.
- ▶ Otras

Variables Aleatorias y Distribución de Probabilidad

Medidas Descriptivas de Variables Aleatorias

Valores Centrales

En el rango de posibles valores de una variable aleatoria, existe un interés natural con respecto a los valores centrales, por ejemplo, el promedio.

Consideremos una variable aleatoria X con soporte Θ_X .

Como cada valor de Θ_X tiene una medida de probabilidad, el **promedio ponderado** es de especial interés.



Variables Aleatorias y Distribución de Probabilidad

Medidas Descriptivas de Variables Aleatorias

Valores Centrales

Al promedio ponderado se le llama también **valor medio** o **valor esperado** de la variable aleatoria X .

Para una variable aleatoria X se define el valor esperado, μ_X , como:

$$\mu_X = E(X) = \begin{cases} \sum_{x \in \Theta_X} x \cdot p_X(x), & \text{Caso Discreto} \\ \int_{-\infty}^{\infty} x \cdot f_X(x) dx, & \text{Caso Continuo} \end{cases}$$

Este valor existe siempre y cuando

$$\sum_{x \in \Theta_X} |x| \cdot p_X(x) < \infty \quad \text{o} \quad \int_{-\infty}^{\infty} |x| \cdot f_X(x) dx < \infty$$

Variables Aleatorias y Distribución de Probabilidad

Medidas Descriptivas de Variables Aleatorias

Otras medidas de centralidad corresponden:

- ▶ **La Moda:** Valor más frecuente o con mayor probabilidad.
- ▶ **La Mediana:** Sea x_{med} el valor que toma la mediana, entonces:

$$F_X(x_{\text{med}}) = 1/2$$

En resumen, el valor esperado de una variable aleatoria es un valor promedio que puede ser visto como un indicador del valor central de la distribución de probabilidad, por esta razón se considera como un parámetro de localización.

Por otra parte, la mediana y la moda de una distribución también son parámetros de localización que no necesariamente son iguales a la media.

Cuando la distribución es simétrica, estas tres medidas son parecidas.



Variables Aleatorias y Distribución de Probabilidad

Medidas Descriptivas de Variables Aleatorias

Medidas de Posición:

Entre las medidas de posición más usuales, se encuentra el mínimo, máximo y percentil $p \times 100\%$.

Si x_p es el valor que toma el percentil $p \times 100\%$, entonces $F_X(x_p) = p$.

Algunos casos particulares de percentil son: Quintiles, cuartiles, deciles, mediana.

Variables Aleatorias y Distribución de Probabilidad

Medidas Descriptivas de Variables Aleatorias

Esperanza matemática

La noción del valor esperado como un promedio ponderado puede ser generalizado para funciones de la variable aleatoria X .

Dada una función $g(X)$, entonces el valor esperado de esta puede ser obtenido como:

$$E[g(X)] = \begin{cases} \sum_{x \in \Theta_X} g(x) \cdot p_X(x), & \text{Caso Discreto} \\ \int_{-\infty}^{\infty} g(x) \cdot f_X(x) dx, & \text{Caso Continuo} \end{cases}$$

Nota: La demostración de este resultado se realizará durante el desarrollo del capítulo 4.

Variables Aleatorias y Distribución de Probabilidad

Medidas Descriptivas de Variables Aleatorias

Función Generadora de Momentos [Rice, 1995 (pág 142 - 144)]

La función generadora de momentos de una variable aleatoria X se define como

$$M_X(t) = E[\exp(t X)]$$

Esta función puede no estar definida para algunos valores de t , pero si existe en un intervalo abierto que contenga al cero, entonces esta función tiene la propiedad de determinar la distribución de probabilidad de X .

Cuando esto último ocurra, esta función permite obtener el r -ésimo momento de X de la siguiente forma

$$M^{(r)}(0) = E(X^r)$$

Variables Aleatorias y Distribución de Probabilidad

Medidas Descriptivas de Variables Aleatorias

Medidas de dispersión

Es de interés cuantificar el nivel de dispersión que tienen una variable aleatoria con respecto a un valor de referencia.

Por ejemplo, nos podría interesar la distancia esperada de los valores de una variable aleatoria X con respecto al valor esperado μ_X , es decir, $E[(X - \mu_X)]$.

Esta idea de dispersión tiene el problema que siempre da como resultado cero.

Variables Aleatorias y Distribución de Probabilidad

Medidas Descriptivas de Variables Aleatorias

Medidas de dispersión

Una alternativa es utilizar la definición de varianza:

$$\begin{aligned}\sigma_X^2 &= \text{Var}(X) = E[(X - \mu_X)^2] \\ &= \begin{cases} \sum_{x \in \Theta_X} (x - \mu_X)^2 \cdot p_X(x), & \text{Caso Discreto} \\ \int_{-\infty}^{\infty} (x - \mu_X)^2 \cdot f_X(x) dx, & \text{Caso Continuo} \end{cases} \\ &= E(X^2) - \mu_X^2\end{aligned}$$

Variables Aleatorias y Distribución de Probabilidad

Medidas Descriptivas de Variables Aleatorias

En términos de dimensionalidad, es conveniente utilizar la desviación estandar, es decir,

$$\sigma_X = \sqrt{\text{Var}(X)}$$

Ahora, si $\mu_X > 0$, una medida adimensional de la variabilidad es el coeficiente de variación (c.o.v)

$$\delta_X = \frac{\sigma_X}{\mu_X}$$

Otras medidas de dispersión son:

$$\text{Rango} = \max - \min$$

$$\text{IQR} = x_{0.75} - x_{0.25}$$



Variables Aleatorias y Distribución de Probabilidad

Medidas Descriptivas de Variables Aleatorias

Medida de asimetría

Se define una medida de asimetría (skewness) corresponde al tercer momento central:

$$E[(X - \mu_X)^3] = \begin{cases} \sum_{x_i \in \Theta_X} (x_i - \mu_X)^3 \cdot p_X(x_i), & \text{Caso Discreto} \\ \int_{-\infty}^{\infty} (x - \mu_X)^3 \cdot f_X(x) dx, & \text{Caso Continuo} \end{cases}$$

Una medida conveniente es el coeficiente de asimetría que se define como:

$$\theta_X = \frac{E[(X - \mu_X)^3]}{\sigma_X^3}$$

Variables Aleatorias y Distribución de Probabilidad

Medidas Descriptivas de Variables Aleatorias




Figure 3.3 Properties of asymmetric PDFs.

Variables Aleatorias y Distribución de Probabilidad

Medidas Descriptivas de Variables Aleatorias

Medida de kurtosis

Finalmente, el cuarto momento central se conoce como la curtosis

$$E[(X - \mu_X)^4] = \begin{cases} \sum_{x_i \in \Theta_X} (x_i - \mu_X)^4 \cdot p_X(x_i), & \text{Caso Discreto} \\ \int_{-\infty}^{\infty} (x - \mu_X)^4 \cdot f_X(x) dx, & \text{Caso Continuo} \end{cases}$$

que es una medida del “apuntamiento” o “achatamiento” de la distribución de probabilidad o de densidad.

Usualmente se prefiere el coeficiente de curtosis

$$K_X = \frac{E[(X - \mu_X)^4]}{\sigma_X^4} - 3$$

Variables Aleatorias y Distribución de Probabilidad

Medidas Descriptivas de Variables Aleatorias

Ejercicio 2

Para el modelo propuesto en el Ejemplo 3.1, muestre que:

(a) $F_X(x) = 1 - e^{-\lambda x}, \quad x > 0.$

(b) $\text{Mediana} = \frac{\ln(2)}{\lambda}.$

(c) $\mu_X = \frac{1}{\lambda}.$

(d) $M_X(t) = \frac{\lambda}{\lambda - t}, \quad t < \lambda.$

(e) $\sigma_X^2 = \frac{1}{\lambda^2}.$

(f) $\delta_X = 1.$

(g) $\theta_X = 2.$

(h) $K_X = 9 - 3 = 6.$

Variables Aleatorias y Distribución de Probabilidad

Medidas Descriptivas de Variables Aleatorias

Ejercicio 3

Para el modelo propuesto en el Ejemplo 3.2, muestre que:

- (a) $\mu_X = \lambda$.
- (b) $M_X(t) = \exp [\lambda (e^t - 1)]$, $t \in \mathbb{R}$.
- (c) $\sigma_X^2 = \lambda$.
- (d) $\delta_X^2 = \frac{1}{\sqrt{\lambda}}$.

Distribuciones de Probabilidad

Teóricamente, cualquier función que satisfaga las condiciones descritas puede ser utilizada para representar una distribución de probabilidad o de densidad de una variable aleatoria, sin embargo, nos interesan algunas funciones que satisfacen:

- ▶ La función es resultado de un proceso físico o puede ser derivada bajo ciertos supuestos.
- ▶ La función es resultado de algunos procesos límites
- ▶ Es ampliamente conocida, y la información esta disponible.
- ▶ Distribución de probabilidad, medidas de descripción, etc.



Distribuciones de Probabilidad

Distribución Normal


En estadística y probabilidad se llama distribución normal, distribución de Gauss o distribución gaussiana, a una de las distribuciones de probabilidad de variable continua que con más frecuencia aparece en fenómenos reales.

La distribución normal fue reconocida por primera vez por el francés **Abraham de Moivre** (1667-1754), en un artículo de 1733 donde relaciona la distribución normal y la binomial.

Posteriormente, el matemático alemán **Carl Friedrich Gauss** (1777-1855) elaboró desarrollos más profundos y formuló la ecuación de la curva; de ahí que asimismo se la conozca, más comúnmente, como campana de Gauss.

Distribuciones de Probabilidad

Distribución Normal



Distribuciones de Probabilidad

Distribución Normal

Muchos fenómenos que encontramos en la naturaleza se miden mediante variables cuya distribución, naturalmente, tienden a formar una campana de Gauss. Además, muchas variables aleatorias continuas presentan una función de densidad cuya gráfica tiene dicha forma.

Finalmente, varios procedimientos estadísticos usados habitualmente asumen la normalidad de los datos observados.

La importancia de esta distribución radica en que permite modelar numerosos fenómenos naturales, sociales y psicológicos.



Distribuciones de Probabilidad

Distribución Normal

La función densidad de una variable aleatoria X con distribución Normal(μ, σ) es de la forma:

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right\}, \quad -\infty < x < \infty$$

con μ parámetro de localización y σ un parámetro de escala o forma tales que:


$$-\infty < \mu < \infty, \quad 0 < \sigma < \infty$$

Distribuciones de Probabilidad

Distribución Normal

Los dos parámetros: μ y σ , permiten describir diferentes distribuciones normales.


Efecto del parámetro μ



Distribuciones de Probabilidad

Distribución Normal

Efecto del parámetro σ



Distribuciones de Probabilidad

Distribución Normal

Un caso especial es cuando $\mu = 0$ y $\sigma = 1$. Este caso es conocido como la distribución normal estándar.

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$


La ventaja es que función de distribución de probabilidad acumulada se encuentra tabulada, la cual se denota por $\Phi(\cdot)$.

Distribuciones de Probabilidad

Distribución Normal

Sea S una variable aleatoria con distribución normal estándar, cuya función de distribución de probabilidad acumulada esta dada por

$$\Phi(s) = F_S(s) = \int_{-\infty}^s \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx$$



Propiedades: $S_p = \Phi^{-1}(p) = -\Phi^{-1}(1 - p)$ y $\Phi(-s) = 1 - \Phi(s)$.

Distribuciones de Probabilidad

Distribución Normal

Tabla Normal Estándar: Resultado de $\Phi(S_p) = p$, para $S_p \geq 0$


S_p	Segunda cifra decimal									
	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767

Distribuciones de Probabilidad

Distribución Normal

Sea X una variable aleatoria $\text{Normal}(\mu, \sigma)$ con función de distribución acumulada F_X . Para dos valores dados a y b (con $a < b$) se tiene que:

$$P(a < X \leq b) = F_X(b) - F_X(a)$$



Distribuciones de Probabilidad

Distribución Normal

Ejercicio 5 Si $X \sim \text{Normal}(\mu, \sigma)$, muestre que:

1. $E(X) = \mu$.
2. $\text{Var}(X) = \sigma^2$.
3. $F_X(x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$.

La función *dnorm()*, *qnorm()* y *pnorm()* de R, evalúan la densidad, calculan percentiles y probabilidades acumuladas respectivamente.

Distribuciones de Probabilidad

Distribución Normal

Ejercicio 6 Durante una tormenta el drenaje de una comunidad se comporta como una variable aleatoria Normal con una media y desviación estándar estimada de 1.2 y 0.4 millones de galones diarios (mgd) respectivamente.

- (a) Si el sistema de drenaje de aguas pluviales fue diseñado para soportar una capacidad máxima de 1.5 mgd. ¿Cuál es la probabilidad que el sistema colapse?
- (b) ¿Cuál es la probabilidad que el sistema deba soportar un drenaje entre 1.0 y 1.6 mgd?
- (c) ¿Cuál es la carga de agua durante una tormenta que soporta el sistema de drenaje correspondiente al percentil 90?



Distribuciones de Probabilidad

Distribución Log-Normal

Se dice que X sigue una ley de probabilidad Log-Normal si su función de densidad esta dada por

$$f_X(x) = \frac{1}{\sqrt{2\pi}} \frac{1}{(\zeta x)} \exp \left[-\frac{1}{2} \left(\frac{\ln x - \lambda}{\zeta} \right)^2 \right], \quad x \geq 0.$$

Donde,


$$\lambda = E(\ln X) \quad \text{y} \quad \zeta = \sqrt{\text{Var}(\ln X)}$$

Propiedad: $\ln X \sim \text{Normal}(\lambda, \zeta)$ (Demostración en el capítulo 4)

La función `dlnorm()`, `qlnorm()` y `plnorm()` de R, evalúan la densidad, calculan percentiles y probabilidades acumuladas respectivamente en el caso Log-Normal.

Distribuciones de Probabilidad

Distribución Log-Normal



Distribuciones de Probabilidad

Distribución Log-Normal

Ejercicio 7


Sea $X \sim \text{Log-Normal}(\lambda, \zeta)$, muestre que

- ▶ $\mu_X = \exp(\lambda + \zeta^2/2)$.
- ▶ Mediana = $\exp(\lambda)$
- ▶ $E(X^k) = \exp(\lambda k) \cdot M_Z(\zeta k)$, con $Z \sim \text{Normal}(0,1)$.
- ▶ $\sigma_X^2 = \mu_X^2(e^{\zeta^2} - 1)$.
- ▶ $\zeta = \sqrt{\ln(1 + \delta_X^2)}$

Distribuciones de Probabilidad

Distribución Log-Normal

Relación δ (c.o.v) vs. ζ



Distribuciones de Probabilidad

Distribución Log-Normal

Ejercicio 8 Considere ahora que la distribución del drenaje se comporta como una variable aleatoria Log-Normal en vez de Normal.

- (a) Si el sistema de drenaje de aguas pluviales fue diseñado para soportar una capacidad máxima de 1.5 mgd. ¿Cuál es la probabilidad que el sistema colapse?
- (b) ¿Cuál es la probabilidad que el sistema deba soportar un drenaje entre 1.0 y 1.6 mgd?
- (c) ¿Cuál es la carga de agua durante una tormenta que soporta el sistema de drenaje correspondiente al percentil 90?



Distribuciones de Probabilidad

Distribución Binomial y Bernoulli

En las más diversas áreas de la Ingeniería, a menudo los problemas involucran la ocurrencia o recurrencia de un evento, el cual es impredecible, como una secuencia de “experimentos”.

Ejemplos:

1. Para un día de lluvia, ¿colapsa o no un sistema de drenaje?
2. Al comprar un producto, ¿éste satisface o no los requerimientos de calidad?
3. Un alumno ¿aprueba o reprueba el curso?

Notar que hay sólo dos resultados posibles para cada “experimento”.



Distribuciones de Probabilidad

Distribución Binomial y Bernoulli

Las variables descritas pueden ser modeladas por una secuencia Bernoulli, la cual se basa en los siguientes supuestos:

1. Cada experimento, tiene una de dos opciones ocurrencia o no ocurrencia del evento.
2. La probabilidad de ocurrencia del evento (“éxito”) en cada experimento es constante (digamos p).
3. Los experimentos son estadísticamente independientes.

Distribuciones de Probabilidad

Distribución Binomial y Bernoulli

Dada una secuencia Bernoulli, si X es el número de ocurrencias del evento éxito entre los n experimentos, con probabilidad de ocurrencia igual a p , entonces la probabilidad que ocurran exactamente x éxitos en los n experimentos esta representada por la distribución Binomial

$$p_X(x) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x = 0, 1, \dots, n$$
$$F_X(x) = \begin{cases} 0, & x < 0 \\ \sum_{k=0}^{[x]} \binom{n}{k} p^k (1-p)^{n-k}, & 0 \leq x < n \\ 1, & x \geq n \end{cases}$$

Distribuciones de Probabilidad

Distribución Binomial y Bernoulli

El valor esperado y varianza están dados por:

$$E(X) = np, \quad \text{Var}(X) = np(1 - p)$$



Las funciones *dbinom()*, *qbinom()* y *pbinom()* de R, evalúan la función de probabilidad, calcula percentiles y probabilidades acumuladas respectivamente en el caso Binomial(*n*, *p*).



Distribuciones de Probabilidad

Distribución Binomial y Bernoulli

Binomial($n = 30, p = 1/2$)



Distribuciones de Probabilidad

Distribución Binomial y Bernoulli

Ejercicio 9 Cinco niveladoras se utilizan en la construcción de una carretera. Suponga que T , vida operacional de cada niveladora, se comporta como una variable aleatoria log-normal con media 1.500 hrs. y c.o.v. del 30%.

Asumiendo independencia entre las niveladoras, determine la probabilidad que:

- (a) exactamente dos presenten una falla en las primeras 900 hrs. de funcionamiento.
- (b) dos o más presenten fallas en las primeras 900 hrs.
- (c) a lo más dos presenten fallas en las primeras 900 hrs.

Distribuciones de Probabilidad

Distribución Geométrica

Dada una secuencia Bernoulli, el número de experimentos hasta la ocurrencia del primer evento exitoso sigue una distribución geométrica.

Si el primer éxito ocurre en el n -ésimo experimento, los primeros $n - 1$ fueron “fracasos”. Si N es la variable aleatoria que representa el número de experimentos hasta el primer éxito, entonces:

$$P(N = n) = p(1 - p)^{n-1}, \quad n = 1, 2, \dots$$



Distribuciones de Probabilidad

Distribución Geométrica

La función distribución esta dada por:

$$F_N(n) = \sum_{k=1}^{[n]} p(1-p)^{k-1} = 1 - (1-p)^{[n]}$$

para $n \geq 1$ y cero en otro caso.

Mientras que su valor esperado y varianza son:



$$E(N) = \frac{1}{p}, \quad \text{Var}(N) = \frac{(1-p)}{p^2}$$

Las funciones *dgeom()*, *qgeom()* y *pgeom()* de R, evalúan la función de probabilidad, calcula percentiles y probabilidades acumuladas respectivamente en el caso Geométrica(*p*).

Distribuciones de Probabilidad

Distribución Binomial y Bernoulli

Geométrica($p = 1/6$)



Distribuciones de Probabilidad

Distribución Geométrica

Tiempo de recurrencia y periodo de retorno

En algunos problemas, el tiempo T (o espacio) es discretizado en intervalos, $T = N$, y puede ser modelado por secuencia Bernoulli.

El número de intervalos ocurridos hasta observar el primer evento exitoso se denomina tiempo medio de recurrencia y corresponde al tiempo entre recurrencias. Este tiempo se conoce como periodo de retorno:


$$\overline{T} = E(T) = \sum_{t=1}^{\infty} t p (1-p)^{t-1} = \frac{1}{p}$$



Distribuciones de Probabilidad

Distribución Geométrica

Ejercicio 10 Una plataforma “costa afuera” es diseñada para soportar olas de hasta 8 metros sobre el nivel medio del mar (ver figura).



Distribuciones de Probabilidad

Distribución Geométrica

Una ola de estas característica tiene una probabilidad del 5% de ocurrencia por año.

Determine:

- ▶ El periodo de retorno.
- ▶ La probabilidad de observar una ola de estas características durante el período de retorno.
- ▶ Probabilidad que ocurra después del tercer año.
- ▶ Probabilidad que ocurra el 5º año, dado que no sucedió durante los primeros tres años.

Distribuciones de Probabilidad

Distribución Binomial Negativa

La distribución geométrica permite modelar el numero de experimentos hasta la primera ocurrencia.

El numero de experimentos hasta la k -ésima ocurrencia de un éxito es modelada por la distribución binomial negativa.



$$P(T_k = x) = \binom{x-1}{k-1} p^k (1-p)^{x-k}, \quad x = k, k+1, k+2, \dots$$

$$E(T_k) = \frac{k}{p}, \quad \text{Var}(T_k) = \frac{k(1-p)}{p^2}$$

Distribuciones de Probabilidad

Distribución Binomial Negativa

$$\text{Bin-Neg}(k = 3, p = 1/6)$$



Distribuciones de Probabilidad

Distribución de Poisson

Muchos problemas físicos de interés para ingenieros y científicos que implican las ocurrencias posibles de eventos en cualquier punto en el tiempo y/o en el espacio.

Por ejemplo:

- ▶ Los terremotos pueden ocurrir en cualquier momento y en cualquier lugar en una región con actividad sísmica en el mundo.
- ▶ Las grietas por fatiga puede producirse en cualquier punto de una soldadura continua.
- ▶ Los accidentes de tráfico pueden suceder en cualquier momento en una autopista.

Distribuciones de Probabilidad

Distribución de Poisson

Este problema puede ser modelado como secuencia Bernoulli, dividiendo el tiempo o el espacio en pequeños intervalos “apropiados” tal que solo un evento puede ocurrir o no dentro de cada intervalo (Ensayo Bernoulli).

Sin embargo, si el evento puede ocurrir al azar en cualquier instante de tiempo (o en cualquier punto del espacio), esto puede ocurrir más de una vez en cualquier momento o intervalo de espacio.

En tal caso, las ocurrencias del evento puede ser más apropiado el modelo con un proceso de Poisson o la secuencia Poisson.



Distribuciones de Probabilidad

Distribución de Poisson

Supuestos:

- ▶ Un evento puede ocurrir al azar y en cualquier instante de tiempo o en cualquier punto en el espacio.
- ▶ La ocurrencia(s) de un evento en un intervalo de tiempo dado (o espacio) es estadísticamente independiente a lo que ocurra en otros intervalos (o espacios) que no se solapen.
- ▶ La probabilidad de ocurrencia de un evento en un pequeño intervalo Δt es proporcional a Δt , y puede estar dada por $\nu \Delta t$, donde ν es la tasa de incidencia media del evento (que se supone constante).
- ▶ La probabilidad de dos o más eventos en Δt es insignificante.

Distribuciones de Probabilidad

Distribución de Poisson

Bajo los supuestos anteriores, el número de eventos estadísticamente independientes en t (tiempo o espacio) está regido por la función de probabilidad del modelo Poisson, donde la variable aleatoria X_t : número de eventos en el intervalo de tiempo $(0, t)$.

$$P(X_t = x) = \frac{(\nu t)^x e^{-\nu t}}{x!} = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x = 0, 1, 2, \dots$$

donde ν es la tasa de ocurrencia media por unidad de tiempo y λ su esperanza en $(0, t)$:

$$E(X_t) = \nu t = \lambda$$

En R, la función `dpois()` evalúa la función de probabilidad y las funciones: `qpois()` y `ppois()`, entregan percentiles y probabilidades acumuladas respectivamente.

Distribuciones de Probabilidad

Distribución de Poisson

Ejercicio 11 Los registros históricos de tormentas severas en una ciudad en los últimos 20 años indica que ha habido un promedio de cuatro tormentas de lluvia por año.

Suponiendo que las ocurrencias de lluvias se pueden modelar con un Proceso de Poisson.

Calcule la probabilidad el próximo año no presente tormentas de lluvias.



Distribuciones de Probabilidad

Distribución Exponencial

Una variable aleatoria X con distribución Exponencial de parámetro $\nu > 0$, tiene función densidad y de distribución:

$$f_X(x) = \begin{cases} \nu e^{-\nu x}, & x \geq 0 \\ 0, & x < 0 \end{cases} \quad F_X(x) = \begin{cases} 0, & x < 0 \\ 1 - e^{-\nu x}, & x \geq 0 \end{cases}$$

Mientras que su valor esperado y varianza son:

$$\mu_X = \frac{1}{\nu}, \quad \sigma_X^2 = \frac{1}{\nu^2}$$

En R, la función `dexp()` evalúa la función de densidad y las funciones: `qexp()` y `pexp()`, entregan percentiles y probabilidades acumuladas respectivamente.

Distribuciones de Probabilidad

Distribución Exponencial

En un Proceso de Poisson el tiempo transcurrido entre la ocurrencia de eventos puede ser descrito por una distribución exponencial.

Si T_1 representa al tiempo transcurrido hasta la ocurrencia del primer evento en un Proceso de Poisson, el evento $(T_1 > t)$ implica que en el intervalo $(0, t)$ no ocurren eventos, es decir,

$$P(T_1 > t) = P(X_t = 0) = \frac{(\nu t)^0 e^{-\nu t}}{0!} = e^{-\nu t},$$

con

$$X_t \sim \text{Poisson}(\nu t)$$

Distribuciones de Probabilidad

Distribución Exponencial

Por lo tanto la función de distribución de probabilidad acumulada de T_1 esta dada por:

$$F_{T_1}(t) = P(T_1 \leq t) = 1 - P(T_1 > t) = 1 - e^{-\nu t}$$

Su función densidad se obtiene como sigue:

$$f_{T_1}(t) = \frac{d}{dt} F_{T_1}(t) = \nu e^{-\nu t}$$

que corresponde a la función densidad de una variable aleatoria con distribución exponencial.

Distribuciones de Probabilidad

Distribución Exponencial

Esta distribución al igual que la geométrica tiene la propiedad de la carencia de memoria, es decir, si $T \sim \text{Exponencial}(\nu)$ entonces se tiene que

$$P(T > t + s \mid T > s) = P(T > t)$$

Este resultado, nos permite asumir que todos los tiempo entre eventos Poisson(ν t) distribuyen Exponencial(ν).

Distribuciones de Probabilidad

Distribución Exponencial

Una variable aleatoria X con distribución Exponencial de parámetro $\nu > 0$, se llama trasladada en a si su función densidad y de distribución acumulada son


$$f_X(x) = \begin{cases} \nu e^{-\nu(x-a)}, & x \geq a \\ 0, & x < a \end{cases} \quad F_X(x) = \begin{cases} 0, & x < a \\ 1 - e^{-\nu(x-a)}, & x \geq a \end{cases}$$

Su valor esperado y varianza están dados por

$$\mu_X = \frac{1}{\nu} + a, \quad \sigma_X^2 = \frac{1}{\nu^2}$$

Distribuciones de Probabilidad

Distribución Exponencial



Distribuciones de Probabilidad

Distribución Gamma

Una variable aleatoria X con distribución Gamma tiene función densidad

$$f_X(x) = \frac{\nu^k}{\Gamma(k)} x^{k-1} e^{-\nu x}, \quad x \geq 0$$

donde k, ν son parámetros positivos.

La función $\Gamma(\alpha) = \int_0^\infty u^{\alpha-1} e^{-u} du$, la cual tiene las siguientes propiedades:

- ▶ $\Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$.
- ▶ $\Gamma(n + 1) = n!$ si $n \in \mathbb{N}_0$.
- ▶ $\Gamma(1/2) = \sqrt{\pi}$.

En R, la función `dgamma()` evalúa la función de densidad y las funciones: `qgamma()` y `pgamma()`, entregan percentiles y probabilidades acumuladas respectivamente.

Distribuciones de Probabilidad

Distribución Gamma

Relación con distribución Poisson

En un Proceso de Poisson el tiempo transcurrido hasta la ocurrencia del k -ésimo evento puede ser descrito por una distribución Gamma.

Si T_k representa al tiempo transcurrido hasta la ocurrencia del k -ésimo evento en un Proceso de Poisson, el evento $(T_k > t)$ implica que en el intervalo $(0, t)$ ocurren a lo más $k-1$ eventos, es decir,

$$P(T_k > t) = P(X_t \leq k - 1) = \sum_{x=0}^{k-1} \frac{(\nu t)^x e^{-\nu t}}{x!}$$

Distribuciones de Probabilidad

Distribución Gamma

Relación con distribución Poisson

Luego, su función de distribución acumulada esta dada por:

$$F_{T_k}(t) = 1 - \sum_{x=0}^{k-1} \frac{(\nu t)^x e^{-\nu t}}{x!}$$

Se puede demostrar que

$$f_{T_k}(t) = \frac{d}{dt} F_{T_k}(t) = \frac{\nu^k}{\Gamma(k)} t^{k-1} e^{-\nu t}, \quad t \geq 0$$

donde su valor esperado y varianza son

$$\mu_{T_k} = \frac{k}{\nu}, \quad \sigma_{T_k}^2 = \frac{k}{\nu^2}$$

Distribuciones de Probabilidad

Distribución Gamma

Ejemplo 3.5 Supongamos que los accidentes mortales en una carretera particular se producen en promedio una vez cada 6 meses.

Si podemos suponer que la incidencia de los accidentes en esta carretera constituye un proceso de Poisson, con tasa de incidencia media de $1/6$ accidentes por mes, el tiempo T_1 hasta la aparición del primer accidente puede describirse como una variable aleatoria exponencial con función densidad:

$$f_{T_1}(t) = \frac{1}{6} e^{-t/6}$$

Distribuciones de Probabilidad

Distribución Gamma

El tiempo T_2 hasta la ocurrencia del segundo accidente puede describirse como una variable aleatoria Gamma con función de densidad:

$$f_{T_2}(t) = \frac{(1/6)^2}{\Gamma(2)} t^{2-1} e^{-t/6}$$


Y el tiempo T_3 hasta la ocurrencia del tercer accidente como una variable aleatoria Gamma con función de densidad:

$$f_{T_3}(t) = \frac{(1/6)^3}{\Gamma(3)} t^{3-1} e^{-t/6}$$



Distribuciones de Probabilidad

Distribución Gamma



Distribuciones de Probabilidad

Distribución Gamma

Una variable aleatoria X tiene distribución Gamma trasladada si su función de densidad esta dada por

$$f_X(x) = \frac{\nu^k}{\Gamma(k)} (x - \gamma)^{k-1} e^{-\nu(x-\gamma)}, \quad x \geq \gamma$$

donde k , μ y γ son parámetros de la distribución.

Su valor esperado y varianza son:

$$\mu_X = \frac{k}{\nu} + \gamma, \quad \sigma_X^2 = \frac{k}{\nu^2}$$



Distribuciones de Probabilidad

Distribución Hipergeométrica

Considere una población finita dividida en dos grupos: m defectuosos y $N - m$ no defectuosos.

Si se toma una muestra aleatoria de tamaño n al azar, la probabilidad que x sean defectuosos esta dada por la función de probabilidad:

$$p_X(x) = \frac{\binom{m}{x} \binom{N-m}{n-x}}{\binom{N}{n}}, \quad \max\{0, n+m-N\} \leq x \leq \min\{n, m\}$$

En este caso, se dice que:

$$X \sim \text{Hipergeométrica}(n, N, m)$$

Distribuciones de Probabilidad

Distribución Hipergeométrica

El cálculo de su valor esperado y varianza requiere un desarrollo bastante complejo cuyo resultado final es el siguiente

$$\mu_X = n \cdot \frac{m}{N}, \quad \sigma_X^2 = \left(\frac{N-n}{N-1} \right) \cdot n \cdot \frac{m}{N} \cdot \left(1 - \frac{m}{N} \right)$$

En R, la función *dhyper()* evalúa la función de probabilidad y las funciones: *qhyper()* y *phyper()*, entregan percentiles y probabilidades acumuladas respectivamente.

Distribuciones de Probabilidad

Distribución Hipergeométrica

Ejemplo 3.6 En una caja de 100 medidores de tensión, se sospecha que puede haber cuatro que están defectuosos.

Si seis de los medidores de la caja se utilizaron en un experimento, la probabilidad de que un medidor defectuoso fuese usado se evalúa como siguiente.

Tenemos que

$$N = 100, \quad m = 4 \quad n = 6$$

Luego

$$P(X = 1) = \frac{\binom{4}{1} \binom{100 - 4}{6 - 1}}{\binom{100}{6}} = 0.205$$

Distribuciones de Probabilidad

Distribución Beta

Una variable aleatoria X con distribución Beta tiene función densidad

$$f_X(x) = \frac{1}{B(r, q)} \cdot \frac{(x - a)^{q-1} (b - x)^{r-1}}{(b - a)^{q+r-1}}, \quad a \leq x \leq b$$

donde q y r son los parámetros de la distribución, y $B(q, r)$ es la función beta dada por


$$B(q, r) = \int_0^1 x^{q-1} (1 - x)^{r-1} dx = \frac{\Gamma(q) \Gamma(r)}{\Gamma(q + r)}$$

$$\mu_X = a + \frac{q}{(q + r)} (b - a) \quad \sigma_X^2 = \frac{q r (b - a)^2}{(q + r)^2 (q + r + 1)}$$

En R, la función `dbeta()` evalúa la función de densidad y las funciones: `qbeta()` y `pbeta()`, entregan percentiles y probabilidades acumuladas respectivamente.

Distribuciones de Probabilidad

Distribución Beta



Otras Distribuciones de Probabilidad

Distribución Weibull

Si $T \sim \text{Weibull}(\eta, \beta)$, se tiene que

$$F_T(t) = 1 - \exp \left[- \left(\frac{t}{\eta} \right)^\beta \right]$$
$$f_T(t) = \frac{\beta}{\eta} \left(\frac{t}{\eta} \right)^{\beta-1} \exp \left[- \left(\frac{t}{\eta} \right)^\beta \right], \quad t > 0$$

Con $\beta > 0$, es un parámetro de forma y $\eta > 0$, es un parámetro de escala.

Si t_p es el percentil $p \times 100\%$, entonces

$$\ln(t_p) = \ln(\eta) + \frac{1}{\beta} \cdot \Phi_{\text{Weibull}}^{-1}(p), \quad \Phi_{\text{Weibull}}^{-1}(p) = \ln[-\ln(1 - p)]$$

Otras Distribuciones de Probabilidad

Distribución Weibull

Mientras que su m -ésimo momento está dado por

$$E(T^m) = \eta^m \Gamma(1 + m/\beta)$$

Luego

$$\mu_T = \eta \Gamma\left(1 + \frac{1}{\beta}\right), \quad \sigma_T^2 = \eta^2 \left[\Gamma\left(1 + \frac{2}{\beta}\right) - \Gamma^2\left(1 + \frac{1}{\beta}\right) \right]$$

En R, la función `dweibull()` evalúa la función de densidad y las funciones: `qweibull()` y `pweibul()`, entregan percentiles y probabilidades acumuladas respectivamente.

Otras Distribuciones de Probabilidad

Distribución Logística

Si $Y \sim \text{Logística}(\mu, \sigma)$, se tiene que

$$F_Y(y) = \Phi_{\text{Logística}}\left(\frac{y - \mu}{\sigma}\right); \quad f_Y(y) = \frac{1}{\sigma} \phi_{\text{Logística}}\left(\frac{y - \mu}{\sigma}\right), \quad -\infty < y < \infty$$

donde

$$\Phi_{\text{Logística}}(z) = \frac{\exp(z)}{[1 + \exp(z)]} \quad \text{y} \quad \phi_{\text{Logística}}(z) = \frac{\exp(z)}{[1 + \exp(z)]^2}$$

son la función de probabilidad y de densidad de una Logística Estándar. $\mu \in \mathbb{R}$, es un parámetro de localización y $\sigma > 0$, es un parámetro de escala.

Otras Distribuciones de Probabilidad

Distribución Logística

Si y_p es el percentil $p \times 100\%$, entonces

$$y_p = \mu + \sigma \Phi_{\text{Logística}}^{-1}(p) \quad \text{con} \quad \Phi_{\text{Logística}}^{-1}(p) = \log\left(\frac{p}{1-p}\right)$$

Su esperanza y varianza están dadas por: $\mu_Y = \mu$ y $\sigma_Y^2 = \frac{\sigma^2 \pi^2}{3}$.

En R, la función *dlogis()* evalúa la función de densidad y las funciones: *qlogis()* y *plogis()*, entregan percentiles y probabilidades acumuladas respectivamente.

Otras Distribuciones de Probabilidad

Distribución Log-Logística

Si $T \sim \text{Log-Logística}(\mu, \sigma)$, se tiene que

$$F_T(t) = \Phi_{\text{Logística}}\left(\frac{\ln(t) - \mu}{\sigma}\right); \quad f_T(t) = \frac{1}{\sigma t} \phi_{\text{Logística}}\left(\frac{\ln(t) - \mu}{\sigma}\right) \quad t > 0$$

$\exp(\mu)$, es un parámetro de escala y $\sigma > 0$, es un parámetro de forma.

Si t_p es el percentil $p \times 100\%$, entonces

$$\ln(t_p) = \mu + \sigma \Phi_{\text{Logística}}^{-1}(p)$$



Otras Distribuciones de Probabilidad

Distribución Log-Logística

Momentos:

Para un entero $m > 0$ se tiene que

$$E(T^m) = \exp(m\mu) \Gamma(1 + m\sigma) \Gamma(1 - m\sigma)$$

El m -ésimo momento no es finito si $m\sigma \geq 1$.

Para $\sigma < 1$

$$\mu_T = \exp(\mu) \Gamma(1 + \sigma) \Gamma(1 - \sigma)$$

y para $\sigma < 1/2$

$$\sigma_T^2 = \exp(2\mu) [\Gamma(1 + 2\sigma) \Gamma(1 - 2\sigma) - \Gamma^2(1 + \sigma) \Gamma^2(1 - \sigma)]$$

Otras Distribuciones de Probabilidad

Distribución t-Student

Un variable aleatoria T tiene distribución t-student si su función de densidad está dada por:

$$f_T(t) = \frac{\Gamma[(\nu + 1)/2]}{\sqrt{\pi \nu} \Gamma(\nu/2)} \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2}, \quad -\infty < t < \infty$$

W. S. Gosset (1908).


- ▶ $\mu_T = 0$, para $\nu > 1$.
- ▶ $\sigma_T^2 = \frac{\nu}{\nu-2}$, para $\nu > 2$.

En R, la función $dt()$ evalúa la función de densidad y las funciones: $qt()$ y $pt()$, entregan percentiles y probabilidades acumuladas respectivamente.

Otras Distribuciones de Probabilidad

Distribución t-Student

Normal Estándar vs. t-Student



Otras Distribuciones de Probabilidad

Distribución Fisher

Si $T \sim \text{Fisher}(\eta, \nu)$, se tiene que

$$f_T(t) = \frac{\Gamma(\frac{\eta+\nu}{2})}{\Gamma(\eta/2)\Gamma(\nu/2)} \left(\frac{\eta}{\nu}\right)^{\frac{\eta}{2}} \frac{t^{\frac{\eta}{2}-1}}{\left(\frac{\eta}{\nu}t + 1\right)^{\frac{\eta+\nu}{2}}}, \quad t > 0$$

- ▶ $\mu_T = \frac{\nu}{\nu-2}$, para $\nu > 2$.
- ▶ $\sigma_T^2 = \frac{2\nu^2(\eta+\nu-2)}{\eta(\nu-2)^2(\nu-4)}$, para $\nu > 4$.

En R, la función $df()$ evalúa la función de densidad y las funciones: $qf()$ y $pf()$, entregan percentiles y probabilidades acumuladas respectivamente.

Múltiples Variables Aleatorias

Los conceptos esenciales definidos para una variable aleatoria pueden ser extendidos a dos o más con la correspondiente distribución de probabilidades conjunta.

Considere por ejemplo dos variables aleatorias:

- ▶ X , pluviosidad en cierta estación meteorológica
- ▶ Y , nivel de un río.

Así, el evento $(X = x, Y = y)$ se puede definir como $(X = x \cap Y = y)$, digamos evento conjunto, de igual forma el evento $(X < x, Y < y)$ puede definirse como el evento conjunto $(X < x \cap Y < y)$ definido para el espacio Θ_{xy} de las variables aleatorias.

Múltiples Variables Aleatorias

Distribución de Probabilidad Conjunta y Condicional

Para el par de variables aleatorias X e Y se define la función de distribución de probabilidad acumulada como

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y)$$

La cual satisface la axiomática fundamental de probabilidades:

- ▶ $F_{X,Y}(-\infty, -\infty) = 0$.
- ▶ $F_{X,Y}(-\infty, y) = 0$.
- ▶ $F_{X,Y}(x, -\infty) = 0$.
- ▶ $F_{X,Y}(x, +\infty) = F_X(x)$.
- ▶ $F_{X,Y}(+\infty, y) = F_Y(y)$.
- ▶ $F_{X,Y}(+\infty, +\infty) = 1$.

Múltiples Variables Aleatorias

Distribución de Probabilidad Conjunta y Condicional

Si las variables aleatorias X e Y son discretas, la función de distribución de probabilidad conjunta es

$$p_{X,Y}(x, y) = P(X = x, Y = y)$$

siendo su función de distribución de probabilidad acumulada igual a

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y) = \sum_{x_i \leq x} \sum_{y_j \leq y} P(X = x_i, Y = y_j),$$

con $(x_i, y_j) \in \Theta_{X,Y}$.

Múltiples Variables Aleatorias

Distribución de Probabilidad Conjunta y Condicional

Ahora, si las variables aleatorias X e Y son continuas, la función de densidad de probabilidad conjunta se define como:

$$f_{X,Y}(x, y) dx dy = P(x < X \leq x + dx, y < Y \leq y + dy)$$

Entonces,

$$F_{X,Y}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(u, v) dv du.$$

Si las derivadas parciales existen, entonces

$$f_{X,Y}(x, y) = \frac{\partial^2}{\partial x \partial y} F_{X,Y}(x, y)$$


Múltiples Variables Aleatorias

Distribución de Probabilidad Conjunta y Condicional

También, se puede observar que la siguiente probabilidad puede ser obtenida como

$$P(a < X \leq b, c < y \leq d) = \int_a^b \int_c^d f_{X,Y}(u, v) du dv$$

que representa el volumen bajo la superficie $f_{X,Y}(x, y)$ como se muestra en la figura.



Múltiples Variables Aleatorias

Distribuciones Marginales y Condicionales

Para variables aleatorias discretas X e Y , la probabilidad de $(X = x)$ puede depender de los valores que puede tomar Y (viceversa).

Con base a lo visto en probabilidades, se define la función de distribución de probabilidad condicional como:

$$p_{X|Y=y}(x) = P(X = x | Y = y) = \frac{p_{X,Y}(x, y)}{p_Y(y)}, \quad p_Y(y) > 0$$

De manera similar, se tiene que

$$p_{Y|X=x}(y) = P(Y = y | X = x) = \frac{p_{X,Y}(x, y)}{p_X(x)}, \quad p_X(x) > 0$$

Múltiples Variables Aleatorias

Distribuciones Marginales y Condicionales

La distribución marginal de una variable aleatoria se puede obtener aplicando el teorema de probabilidades totales.

Para determinar la distribución marginal de X , $p_X(x)$, tenemos que

$$\begin{aligned} p_X(x) &= \sum_{y \in \Theta_Y} p_{X|Y=y}(x) \cdot p_Y(y) \\ &= \sum_{y \in \Theta_Y} p_{X,Y}(x, y) \end{aligned}$$

De la misma forma se tiene que

$$p_Y(y) = \sum_{x \in \Theta_X} p_{X,Y}(x, y)$$

Múltiples Variables Aleatorias

Distribuciones Marginales y Condicionales

En el caso que ambas sean variables aleatorias continuas se define la función de densidad condicional de X dado que $Y = y$ como

$$f_{X|Y=y}(x) = \frac{f_{X,Y}(x,y)}{f_Y(y)} \quad f_Y(y) > 0$$

De manera similar se tiene que

$$f_{Y|X=x}(y) = \frac{f_{X,Y}(x,y)}{f_X(x)} \quad f_X(x) > 0$$

Las respectivas marginales se obtienen como sigue:

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y) dy$$
$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x,y) dx$$

Múltiples Variables Aleatorias

Distribuciones Marginales y Condicionales

En el caso mixto, supongamos X discreta e Y continua, el calculo de las respectivas marginales es

$$p_X(x) = \int_{-\infty}^{\infty} p_{X|Y=y}(x) \cdot f_Y(y) dy$$
$$f_Y(y) = \sum_{x \in \Theta_X} f_{Y|X=x}(y) \cdot p_X(x)$$

Múltiples Variables Aleatorias

Distribuciones Marginales y Condicionales

Si ambas variables aleatorias son independientes, entonces se tiene que

$$p_{X,Y}(x,y) = p_X(x) \cdot p_Y(y)$$

$$f_{X,Y}(x,y) = f_X(x) \cdot f_Y(y)$$



Múltiples Variables Aleatorias

Distribuciones Marginales y Condicionales

Ejemplo 3.7: Considere un autopista concesionada y un portico TAG en particular.

Datos históricos indica que el $p \times 100\%$ de los automóviles adulteran su placa patente para no pagar TAG. Suponga que en promedio pasan en una hora ν automóviles según un proceso de Poisson.

Proponga una distribución conjunta para las siguientes variables aleatorias:

- ▶ X : Número de vehículos que pasan en una hora por el portico.
- ▶ Y : Número de vehículos que pasan con patente adulterada en una hora por el portico.

Múltiples Variables Aleatorias

Distribuciones Marginales y Condicionales

Tenemos que

$$X \sim \text{Poisson}(\nu) \quad y \quad Y | X = x \sim \text{Binomial}(x, p)$$

Luego

$$\begin{aligned} p_{X,Y}(x, y) &= p_{Y|X=x}(y) \cdot p_X(x) \\ &= \binom{x}{y} p^y (1-p)^{x-y} \cdot \frac{\nu^x e^{-\nu}}{x!} \end{aligned}$$

$$\Theta_{X,Y} = \{(x, y) \mid x \in \mathbb{N}_0, y \in \mathbb{N}_0, y \leq x\}.$$

Por probabilidades totales se tiene que

$$Y \sim \text{Poisson}(\nu p)$$

Múltiples Variables Aleatorias

Distribuciones Marginales y Condicionales

```
p.xy = function(x, y, p = 0.05, nu = 50){  
  n.r = length(x)  
  n.c = length(y)  
  M = matrix(NA, ncol = n.c, nrow = n.r)  
  for(i in 1:n.r){  
    M[i,] = dbinom(y, size = x[i], prob = p)*dpois(x[i],  
    lambda = nu)  
  }  
  M  
}
```

```
x = 0:100  
y = 0:20  
z = p.xy(x, y, p = 0.20, nu = 50)
```

Múltiples Variables Aleatorias

Distribuciones Marginales y Condicionales


```
Z = c(z)
X = rep(x, length(y))
Y = sort(rep(y, length(x)))

install.packages("scatterplot3d")
library(scatterplot3d)
scatterplot3d(x = X, y = Y, z = Z, type = "h", lwd=2, pch= "",
xlab = "X", ylab = "Y", zlab = "", highlight.3d=TRUE, angle = 45)
```



Múltiples Variables Aleatorias

Distribuciones Marginales y Condicionales



Múltiples Variables Aleatorias

Distribuciones Marginales y Condicionales

Ejemplo 3.8: Sean X e Y variables aleatorias continuas, relacionadas de la siguiente manera:

$$Y \sim \text{Gamma}(k, \nu) \quad \text{y} \quad X | Y = y \sim \text{Uniforme}(0, y)$$

Luego

$$f_{X,Y}(x,y) = \frac{\nu^k}{\Gamma(k)} y^{k-1} e^{-\nu y} \cdot \frac{1}{y}, \quad 0 \leq x \leq y$$

Múltiples Variables Aleatorias

Distribuciones Marginales y Condicionales

```
f.xy = function(x, y, k = 3, nu = 2){  
  n.r = length(x)  
  n.c = length(y)  
  M = matrix(NA, ncol = n.c, nrow = n.r)  
  for(i in 1:n.r){  
    M[i,] = dgamma(y, rate = nu, shape = k)*dunif(x[i], 0, y)  
  }  
  M  
}  
x = seq(0,5,.05)  
y = seq(0,5,.05)  
z = f.xy(x, y)  
install.packages("rgl")  
library(rgl)  
rgl.surface(x = x, y = z, z = y, color = "red", back="lines")
```

Múltiples Variables Aleatorias

Distribuciones Marginales y Condicionales

Ejemplo 3.9: Dos variables aleatorias X e Y tienen distribución conjunta Normal-Bivariada si su función de densidad conjunta está dada por:

$$f_{X,Y}(x,y) = \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} \times \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_X}{\sigma_X}\right)^2 + \left(\frac{y-\mu_Y}{\sigma_Y}\right)^2 - 2\rho\left(\frac{x-\mu_X}{\sigma_X}\right)\left(\frac{y-\mu_Y}{\sigma_Y}\right)\right]\right\}$$

A partir de esto se puede deducir que

$$X \sim \text{Normal}(\mu_X, \sigma_X), \quad Y \sim \text{Normal}(\mu_Y, \sigma_Y)$$

$$Y | X = x \sim \text{Normal}\left(\mu_Y + \frac{\rho\sigma_Y}{\sigma_X}(x - \mu_X), \sigma_Y\sqrt{(1-\rho^2)}\right)$$

Múltiples Variables Aleatorias

Distribuciones Marginales y Condicionales

```
f.xy = function(x, y, mu.x = 0, mu.y = 0, s.x = 1, s.y = 1,
rho = 0){
  n.r = length(x)
  n.c = length(y)
  M = matrix(NA, ncol = n.c, nrow = n.r)
  for(i in 1:n.r){
    M[i,] = dnorm(x[i], mean = mu.x, sd = s.x) * dnorm(y, mean = mu.
+ rho*s.y*(x[i]-mu.x)/s.x, sd = s.y*sqrt(1-rho^2))
  }
  M
}

x = seq(-5,5,0.1)
y = seq(-5,5,0.1)
z = f.xy(x, y, rho = 0)
rgl.surface(x = x, y = z*10, z = y, color = "red", back="lines")
```

Múltiples Variables Aleatorias

Covarianza y Correlación

Cuando hay dos variable aleatoria X e Y , puede haber una relación entre las variables.

En particular, la presencia o ausencia de relación estadística lineal se determina observando el primer momento conjunto de X e Y definido como

$$E(X Y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy \cdot f_{X,Y}(x, y) dx dy$$

Si X e Y son estadísticamente independientes, entonces

$$E(X Y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy \cdot f_X(x) \cdot f_Y(y) dx dy = E(X) \cdot E(Y)$$

Múltiples Variables Aleatorias

Covarianza y Correlación

La covarianza corresponde al segundo momento central y se define como:

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E(X \cdot Y) - \mu_X \cdot \mu_Y$$

Si X e Y son estadísticamente independientes, entonces

$$\text{Cov}(X, Y) = 0$$

El significado físico de la covarianza se puede inferir de la ecuación.

Si la $\text{Cov}(X, Y)$ es grande y positivo, los valores de X e Y tienden a ser grandes o pequeños en relación a sus respectivos medias, mientras que si la $\text{Cov}(X, Y)$ es grande y negativo, los valores de X tienden a ser grandes con respecto a su media, mientras que los de Y tienden a ser pequeños.

Múltiples Variables Aleatorias

Covarianza y Correlación

El significado físico de la covarianza se puede inferir de la ecuación anterior:

- ▶ Si $\text{Cov}(X, Y)$ es grande y positiva, los valores de X e Y tienden a ser grandes (o pequeños) en relación a sus respectivos medias.
- ▶ Si $\text{Cov}(X, Y)$ es grande y negativo, los valores de X tienden a ser grandes con respecto a su media, mientras que los de Y tienden a ser pequeños y viceversa.
- ▶ Si $\text{Cov}(X, Y)$ es pequeña o cero, la relación (lineal) entre los valores de X e Y es poca o nula, o bien la relación es No lineal.

Múltiples Variables Aleatorias

Covarianza y Correlación

La covarianza mide el grado de asociación lineal entre dos variables, pero es preferible su normalización llamada correlación para poder cuantificar la magnitud de la relación.





La Correlación esta definida como:

$$\text{Cor}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \cdot \sigma_Y}$$

Este coeficiente toma valores en el intervalo $(-1, 1)$.



Múltiples Variables Aleatorias

Covarianza y Correlación



Múltiples Variables Aleatorias

Covarianza y Correlación



Esperanza Condicional y Predicción (Rice Sec 4.4)

Definiciones y Ejemplos

El valor esperado de una variable aleatoria Y condicionado a la realización x de una variable aleatoria X esta dado por

$$E(Y | X = x) = \begin{cases} \sum_{y \in \Theta_{Y|X=x}} y \cdot P(Y = y | X = x), & \text{caso discreto} \\ \int_{y \in \Theta_{Y|X=x}} y \cdot f_{Y|X=x}(y) dy, & \text{caso continuo} \end{cases}$$

Esperanza Condicional y Predicción (Rice Sec 4.4)

Definiciones y Ejemplos

Por otra parte, para una función de Y , llamemos $h(Y)$, el valor esperado condicional esta dado por

$$E[h(Y) | X = x] = \begin{cases} \sum_{y \in \Theta_{Y|X=x}} h(y) \cdot P(Y = y | X = x), & \text{caso discreto} \\ \int_{y \in \Theta_{Y|X=x}} h(y) \cdot f_{Y|X=x}(y) dy, & \text{caso continuo} \end{cases}$$

Esperanza Condicional y Predicción (Rice Sec 4.4)

Definiciones y Ejemplos

Ejemplo 3.10

Considere un proceso de Poisson cuyo número de eventos esperado en $[0, 1]$ es λ . Si N y X son variables aleatorias que determinan la cantidad de eventos en los intervalos $[0, 1]$ y $[0, p]$ respectivamente, con $0 < p < 1$, muestre que $E(X \mid N = n) = np$.

Esperanza Condicional y Predicción (Rice Sec 4.4)

Definiciones y Ejemplos

Ejemplo 3.11

Sean X e Y dos variables aleatorias cuya distribución de probabilidad conjunta está determinada por una Normal bivariada de parámetros μ_X , μ_Y , σ_X , σ_Y y ρ .

Muestre que

$$E(Y | X = x) = \mu_Y + \rho(x - \mu_X) \sigma_Y / \sigma_X \quad \text{y} \quad \text{Var}(Y | X = x) = \sigma_Y^2 (1 - \rho^2)$$

Esperanza Condicional y Predicción

Definiciones y Ejemplos

Teorema de probabilidades totales para valor esperado

$$E(X) = \begin{cases} \sum_{y \in \Theta_Y} \left[\sum_{x \in \Theta_{X|Y=y}} x \cdot p_{X|Y=y}(x) \right] p_Y(y), & \text{Caso Discreto-Discreto} \\ \int_{y \in \Theta_Y} \left[\int_{x \in \Theta_{X|Y=y}} x \cdot f_{X|Y=y}(x) dx \right] f_Y(y) dy, & \text{Caso Continuo-Continuo} \\ \int_{y \in \Theta_Y} \left[\sum_{x \in \Theta_{X|Y=y}} x \cdot p_{X|Y=y}(x) \right] f_Y(y) dy, & \text{Caso Discreto-Continuo} \\ \sum_{y \in \Theta_Y} \left[\int_{x \in \Theta_{X|Y=y}} x \cdot f_{X|Y=y}(x) dx \right] p_Y(y), & \text{Caso Continuo-Discreto} \end{cases}$$

Esperanza Condicional y Predicción (Rice Sec 4.4)

Definiciones y Ejemplos

Teoremas Esperanza Iterada

$$E(Y) = E[E(Y | X)]$$

$$\text{Var}(Y) = \text{Var}[E(Y | X)] + E[\text{Var}(Y | X)]$$



Esperanza Condicional y Predicción (Rice Sec 4.4)

Predicción

Predecir el valor de una variable aleatoria a partir de otra es el propósito de esta sección.

Consideremos primero la siguiente situación: “Predecir la realización de una variable aleatoria Y ”. El “mejor” valor c para predecir la realización de Y se puede obtener minimizando el error cuadrático medio definido como

$$\text{ECM} = E[(Y - c)^2]$$

Mostrar que la constante c que minimiza el ECM es $E(Y)$.

Esperanza Condicional y Predicción (Rice Sec 4.4)

Predicción

Si ahora queremos predecir Y basado en una función de una variable aleatoria X , llamemos $h(X)$, que minimice el error cuadrático medio definido como

$$\begin{aligned}\text{ECM} &= E \{ [Y - h(X)]^2 \} \\ &= E (E \{ [Y - h(X)]^2 \mid X \})\end{aligned}$$

Entonces, la función $h(X)$ que minimiza ECM necesariamente debe corresponder a $E(Y \mid X)$.

Por ejemplo, si X e Y distribuyen conjuntamente según una Normal bivariada, entonces el mejor predictor Y basado en X es una función lineal dada por

$$E(Y \mid X) = \left(\mu_Y - \mu_X \frac{\rho \sigma_Y}{\sigma_X} \right) + X \frac{\rho \sigma_Y}{\sigma_X}$$